

卒 業 論 文

表現条件付き潜在拡散モデルの提案 -脳CT画像の血腫分類-

2023年度

九州工業大学情報工学部

知能情報工学科

202C1020

浮田 嵩祐

指導教員：大北 剛 准教授

		指導教員	大北 剛 准教授
学生番号	202C1020	氏名	浮田 嵩祐
論文題目	表現条件付き潜在拡散モデルの提案 -脳 CT 画像の血腫分類-		

1 はじめに

本論文では、まず、変分オートエンコーダで圧縮された潜在空間上で動作するトランスフォーマーベースの拡散モデルである拡散トランスフォーマー DiT[1] をベースラインとし、その内部に画像表現をエンコードするビジョントランスフォーマー [2] を組み込み、表現で条件付けられた画像生成モデルを提案する。次に、自己教師あり表現学習として、拡散モデルを使用する手法を提案する。ダウンストリームタスクにおける画像分類結果が強力な対照学習手法であるビジョントランスフォーマー DINOv2[3] を上回ることを示す。

2 表現条件付き潜在拡散モデル




図 1: 表現条件付き潜在拡散モデル

図 1 は、変分オートエンコーダで圧縮した潜在空間上での順拡散プロセスと、エンコードされた画像表現をデノイズアーキテクチャに結合しながらノイズ除去を行う逆拡散プロセスをモデル化したものである。すでに訓練済みのエンコーダから得られた表現を条件付けるインスタンススペースの拡散モデルとは異なり、我々の提案手法は潜在拡散モデル内部でエンコーダも同時に訓練され表現が最適化される。これを、トランスフォーマーをベースとした表現条件付き潜在拡散モデルとして構築した。

自己教師あり表現学習として拡散モデルを用いた手法は、まず、表現条件付き潜在拡散モデルを訓練する。次に、クラス条件付き潜在拡散モデルにロードし少量

のデータセットでファインチューニングを行う。最後に、クラス条件付き潜在拡散モデルからクラス分類子を取り出し、分類結果を得て評価する。

3 実験結果・結論

脳 CT 画像データセットを使用して実験を行った。表 1 は、条件別の潜在拡散モデルの評価結果である。我々が提案する表現条件付き潜在拡散モデルは、オリジナルの DiT と比較すると、FID が 15.69 向上した。表 2 は、自己教師あり表現学習として拡散モデルを用いた手法の評価結果である。分類結果は Accuracy が 6.15%, F 値が 13.6%, DINOv2 を上回った。

表 1: DiT(Class Label) と無条件、表現条件付きモデルの評価結果

Conditions	FID	sFID	IS	Precision	Recall
Class Label	25.69	21.57	3.257	0.39	0.36
None	24.42	20.98	3.117	0.40	0.39
Representation	10.00	12.20	3.204	0.94	0.99

表 2: 血腫分類結果

Pre-training	Classification	Accuracy	F-score	Recall	Precision
None	ResNet50	0.7150	0.4950	0.8928	0.3424
None	ViT B	0.8659	0.5200	0.4642	0.5909
DINOv2	Linear	0.8882	0.6875	0.7857	0.6111
無条件 DiT	zero-shot	0.8882	0.7058	0.8571	0.6000
表現条件付き DiT	zero-shot	0.9497	0.8235	0.7500	0.9130

参考文献

- [1] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv preprint arXiv:2212.09748*, 2022.
- [2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [3] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.

目次

第1章	はじめに	1
第2章	基礎事項	3
2.1	潜在拡散モデル	3
第3章	関連研究	6
3.1	ビジョントランスフォーマー DINO	6
3.2	拡散トランスフォーマー Diffusion Transformers(DiT)	7
第4章	我々の提案	8
4.1	拡散トランスフォーマー (DiT) を使用した画像生成	10
4.2	潜在拡散モデルでの表現学習	14
4.2.1	無条件潜在拡散モデルを使用した画像の表現学習	14
4.2.2	表現条件付き潜在拡散モデルを使用した画像の表現学習	16
第5章	実験結果	18
5.1	データセット	18
5.2	血腫分類	19
5.3	拡散トランスフォーマー (DiT) を使用した画像生成	21
5.4	潜在拡散モデルでの表現学習	25
第6章	結論	34

第1章 はじめに

画像生成に関する研究は、これまで急速に発展してきた。テキスト条件付き (text-to-image) の画像生成法は、プロンプトと呼ばれるテキスト情報に依存した画像を生成可能にし注目を浴びた。GAN を使用したモデルをはじめとして、VQ-VAE[1] での画像生成アプローチをテキスト条件付きに適応させるため自己回帰 Transformer を組み込み提案された。また、DALL-E[2] では、このテキスト条件付き画像生成アプローチに CLIP[3] を用いて、出力画像をランク付けすることでよりプロンプトに沿った画像を生成することに成功した。そこから改良された DALL-E 2[4] では、拡散モデルが使用され、CLIP によるテキスト埋め込みを条件付けることで、性能を上げた。さらに、VAE[5] による潜在空間上で動作する拡散モデルとして構築された Stable Diffusion(Latent Diffusion Models)[6] は、優れた計算効率と高性能な生成を実現し、大きな印象を与えた。

画像生成はテキストからの生成にとどまらず、画像表現を条件 (image-to-image) とした生成モデルも提案されてきた。Bordes et al.[7] は対照学習モデルからの画像表現を条件付けた拡散モデルを提案した。カーネル密度推定を使用し画像表現をサンプリングすることにより、2段階の画像生成のための簡単なアプローチを実験した。これらの生成された表現を拡散モデルに与えることで、画像をエンドツーエンドで生成可能にした。また、Jeremias[8] は、学習済みの画像表現だけでなく、拡散モデル内でエンコードした表現を与えて訓練する表現条件付き拡散モデルを考案した。

本論文では、このような生成モデルで学習された表現を用いて、画像認識を行う手法を考える。ラベルなし画像を自己教師あり表現学習により画像表現を学習し、ダウンストリームタスクで画像認識を行うこの流れは、これまで多くの研究では対照学習による手法で効果が大いにと示された。しかし、ここで改めて考えてほしい。画像認識は画像から表現を得る過程であり、画像生成は表現から画像を得る過程である。精細な画像を生成するための表現は、生成モデルでこそ学習され、その得られた表現を用いることで画像認識においても高性能な結果が得られると考えられる。

拡散モデル内部はノイズ情報で制御されており、明示的な画像表現と呼ばれる要素は存在しない。しかし、強力な生成モデルである拡散モデルは画像認識に長

けた画像表現が学習されていると考え、我々は、拡散モデルを用いた表現学習というアプローチを提案する。

論文の構成

第2章では、本論文で取り上げる潜在拡散モデルの手法について述べる。第3章では、関連研究としてビジョントランスフォーマーの一派 DINO[9] と本研究のベースラインに設定した拡散トランスフォーマー DiT[10] について述べる。第4章では、4.1 節で DiT の詳細なアルゴリズムについて述べる。4.2 節で提案手法である表現条件付き潜在拡散モデルと自己教師あり表現学習として拡散モデルを使用した手法について述べる。第5章は、実験に使用したデータと、拡散モデルから分類子を取り出す手法、実験結果について述べる。第6章では、本研究の結論を述べる。付録では、本研究の基礎的な知識として、対数尤度の下限を表す ELBO、変分オートエンコーダ、拡散モデルについて述べる。

第2章 基礎事項

第2章では，潜在拡散モデルについて述べる．本研究では，この潜在拡散モデルを発展させた手法を取り扱う．

2.1 潜在拡散モデル

従来の拡散モデルは，トレーニングとサンプリングどちらもピクセル画像の高次元空間での評価と勾配計算の繰り返しが必要になるため，計算量が膨大になるという欠点がある．そこで，トレーニングとサンプリングの両方において性能を




図 2.1: 知覚的圧縮と意味的圧縮 [6].

損なわずに計算量を減らすことは拡散モデルを多くの人に扱えるようにするために必要不可欠である．図 2.1 は，訓練済みモデルの歪み率とレートのトレードオフを表した図である．図中の横軸の bits/dim は知覚できないほどの細部を表す．従来の拡散モデルでは，知覚的圧縮と意味的圧縮の両方を同時に学習していた．

- **知覚的圧縮 (Perceptual Compression):** 高周波の詳細なノイズを除去するが，意味的な変化はほとんど学習されない．
- **意味的圧縮 (Semantic Compression):** 実際の生成モデルがデータの意味的な構成を学習する．

デジタル画像のほとんどのビットは，知覚できない細部に対応している．拡散モデルを用いると，損失項を最小化することでこの無意味な情報を抑制できるが，勾配とニューラルネットワークのバックボーンは依然としてすべてのピクセルで評価する必要がある，余計な計算につながる．

そこで，効果的な生成モデルとして潜在拡散モデル (LDM)[6] を提案し，知覚できない細部のみを除去するマイルドな圧縮段階を別に設ける．この場合，LDM が意味的圧縮を行い，マイルドな圧縮段階が知覚的圧縮を行う．潜在拡散モデルのアプローチは次の 2 つのプロセスで表される．

- データ空間と知覚的に等価な低次元の表現空間を提供するオートエンコーダを訓練する．
- 画像 x の拡散モデルの代わりに，表現 $z = E(x)$ の拡散モデルを学習する．

図 2.2 は潜在拡散モデルのアーキテクチャを示している．大きく 2 つの部分に分かれている．1 つは，画像を潜在空間にエンコード，もしくは表現から画像にデコードを行う知覚的画像圧縮を行うピクセル空間であり，もう 1 つの潜在空間は，拡散モデルを構築し画像の意味的な構成を理解するスペースである．




図 2.2: 潜在拡散モデル [6].

知覚圧縮モデルとして，知覚損失とパッチベースの目的関数を組み合わせて訓練したオートエンコーダを用いている．これによって，再構成したデータが画像に限定されることを保証し，L2 ノルムやL1 ノルムなどのピクセル空間の損失のみに依存することで生じるぼやけを回避している．潜在空間が過度に高分散化するのを避けるため，2つの異なる正則化を試している．一つはKL-regであり，VAEと同様に学習した潜在空間上の標準正規系に対するわずかなKLペナルティを課す．もう一方はVQ-regであり，オートエンコーダのデコーダ内でのベクトル量子化による正則化項である．いずれにせよ，エンコードされた潜在変数がガウシアン正規分布 $N(0, I)$ に近づくようにする．

知覚圧縮モデルの学習により，高周波で知覚できない細部が抽象化された効率的な低次元の潜在空間が利用できるようになった．この空間は，高次元の画素空間と比較して，尤度ベースの生成モデルに適しており，データの重要な意味的ビットに焦点を当て，低次元で計算効率の高い空間で訓練することができる．潜在拡散モデル内で行っていることはDDPM[11]とほとんど変わらず，違いは潜在空間にエンコード・デコードしているという点のみである．

第3章 関連研究

本論文では、拡散モデルを用いて、ラベルなし画像を自己教師あり学習により画像表現を学習し、ダウンストリームタスクで画像認識を行うこの流れを提案する。3.1節では、このプロセスに関連する研究として強力な対照学習手法であるDINOについて述べる。3.2節では、本研究のベースラインに設定した拡散トランスフォーマー DiT について述べる。

3.1 ビジントランスフォーマー DINO

MoCo[12] や SimCLR[13]などを代表例とする自己教師あり表現学習の研究は、インスタンス分類という識別アプローチに焦点を当てている。これは、一般的な対照学習でのアプローチといえる。表現空間内で類似のインスタンスが互いに近くに配置され、異なるインスタンスが遠く離れている表現を学習することを目的とする。このアプローチの欠点は、画像1枚を学習するためにそれとは異なる画像が大量に必要であり効率的ではないところである。この欠点を改良するため、画像を区別することなく教師なしで特徴を学習できるBYOL[14]という手法が提案された。これは、データ拡張を用いた非対称的な入力と、stop-gradientを用いた非対称的な重み更新による2つの非対称性を生み出し、2つのネットワークの出力の類似度を小さくするように訓練を行う手法である。DINO[9]はBYOLからインスピレーションを得て考案された。

図3.1は、DINO[9]のアルゴリズムを表している。このモデルは、入力画像に対して、2つの異なるランダム変換を施し、生徒(student) g_{θ_s} と教師(teacher) g_{θ_t} のネットワークにそれぞれ入力する。教師ネットワークの出力は、バッチ全体で計算された平均値を中心に配置され(centering)、各ネットワークは、特徴次元に渡るソフトマックス(softmax)で正規化されたK次元特徴を出力し、それらの類似性がクロスエントロピー損失を使用して測定される。どちらのネットワークもアーキテクチャは同じであるが、パラメータは異なり、教師ネットワークにはstop-gradient(sg)を適用し、生徒ネットワークを介してのみ勾配伝播を行う。教師パラメータは、生徒パラメータの指数移動平均(ema)で更新される。




図 3.1: DINO のアルゴリズム [9].

DINO v2

DINO v2[15] は DINO の改良版モデルであり, SwAV[16] という対照学習手法を中心として DINO と iBOT[17] を組み合わせ, 考案された.

DINO から大きく変わる点としては, DINO アルゴリズムに加えて生徒ネットワークへ入力する画像パッチの一部をマスクするということだ. またデータセットのキュレーションや細かなコンポーネントの追加によりロバストで高パフォーマンスなモデルとして提案された.

3.2 拡散トランスフォーマー Diffusion Transformers(DiT)

機械学習はトランスフォーマー [18] によってルネサンスを迎えている. 自然言語処理, ビジョン, その他いくつかの領域のためのニューラルアーキテクチャは, トランスフォーマーにほぼ吸収されてきた. しかし, 画像レベルの生成モデルの多くは, このトレンドに乗れていない. トランスフォーマーは自己回帰モデルでは広く使われているが, 他の生成モデルのフレームワークではあまり採用されていないように思われる. 拡散モデルにおいて, バックボーンアーキテクチャは畳み込み U-Net がよく採用されている. ここでは, トランスフォーマーに基づく新たな拡散モデルに焦点をあて, Diffusion Transformers(DiT)[10] を構築する.

第4章 我々の提案

第4章では、潜在空間上で動作するトランスフォーマー [18] を用いた拡散モデル (DiT[10]) をベースラインとして設定し、DiTの詳細な手法と表現学習を行うために改良した手法について述べる。その際、使用したアーキテクチャの図を計3つ提示するが、それぞれの違いを明確にするためにまとめて以下に示す。ここでは、図は小さく示してあるが、後続の節でそれぞれ拡大した図を示す。




図 4.1: クラス条件付き潜在拡散モデル




図 4.2: 無条件潜在拡散モデル




図 4.3: 表現条件付き潜在拡散モデル

また、ここでの条件とは、サンプリングするときどのような画像を生成する

かを制御する対象を総称してそう呼ぶことにする．トレーニング時，デノイズアーキテクチャに条件を渡しながらか学習することで，サンプリング時に条件に沿った画像を生成することが可能になる．

図 4.1 は，オリジナルの DiT アーキテクチャであり，クラス条件付き潜在拡散モデルを表している．詳細は 4.1 説で説明する．

図 4.2 は，無条件潜在拡散モデルを表し，クラス条件付き潜在拡散モデル (図 4.1) からクラスラベル y の条件付けを除いたモデルである．詳細は 4.2.1 節で説明する．

図 4.3 は，表現条件付き潜在拡散モデルを表し，変分オートエンコーダにより潜在空間上に圧縮された画像をビジョントランスフォーマー [19] で表現 r にエンコードし，デノイズプロセスに結合する処理を施している．詳細は 4.2.2 節で説明する．

4.1 拡散トランスフォーマー (DiT) を使用した画像生成




図 4.4: クラス条件付き潜在拡散モデル

図 4.4 は、DiT[10] のアーキテクチャであり、クラス条件付き潜在拡散モデルを表す。VAE¹ 潜在空間上での順拡散プロセスと、逆拡散プロセスをモデル化している。デノイズアーキテクチャがトランスフォーマー [18] を改良して構築されており、タイムステップ t とクラスラベル y をそれぞれ埋め込んだ後、乗算と加算でデノイズアーキテクチャに渡される。

拡散モデルは、訓練後画像の生成を目的としてモデリングされており、完全なガウシアンノイズから 1 ステップずつノイズの除去を行い最終的には鮮明な画像を生成することが可能である。その過程をサンプリングと呼び、このモデルでは、サンプリング時にクラスラベルを指定することでクラスラベルによって条件付けられた画像が生成される。図 4.4 では、 z_T ² から z_0 までデノイズされ、デコーダ D を通り画像 x' までの過程がサンプリングを表している。

モデルの学習はサンプリング時とは少し異なる。一般的に拡散モデルの学習は、確率密度関数 $p_\theta(x_{t-1}|x_t)$ におけるパラメータ θ を最適化することであり、これは

¹変分オートエンコーダ (Variational AutoEncoder)

²完全なガウシアンノイズ

特定のタイムステップ t に依存しない。したがって、デノイズの学習はランダムな t に関して z_t を入力とし、その画像に付与された減衰前のノイズ ϵ を出力することを想定しており、その出力 ϵ_θ と ϵ の平均二乗誤差を下げるよう学習される。また、潜在拡散モデルは潜在空間上での拡散モデルであり、モデルの訓練は画像を潜在空間に圧縮してからは潜在空間上で完結するため、従来のピクセルレベルの拡散モデルと比べ、低次元で計算効率の高い訓練が可能である。

Training

Algorithm 1 Training: PyTorch pseudo code

```

1  for x, y in loader:
2      z0 = E(x)
3
4      t = torch.randint(0, 1000, (z0.shape[0],))
5      noise = torch.randn_like(z0)
6      zt =  $\sqrt{\bar{\alpha}_t}$ *z0 +  $\sqrt{1 - \bar{\alpha}_t}$ *noise
7
8      output = model(zt, t, y)
9
10     loss = mean((noise - output)**2)
11
12     optim.zero_grad()
13     loss.backward()
14     optim.step()

```

入力 x は $256 \times 256 \times 3$ の画像を表す。この画像をエンコーダ E に通し、 $32 \times 32 \times 4$ の潜在変数 z_0 に圧縮する。ここでのエンコーダ E は、Stable Diffusion[6]によって公開されているVAE³を使用している。

順拡散プロセスでは、図4.5に示してある通り、 $\beta(0 \leq \beta \leq 0.02)$ を線形にスケジューリングしており、 α 、 $\bar{\alpha}$ は式(4.1)、(4.2)で表せる。

$$\alpha_t = 1 - \beta_t \quad (4.1)$$

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s \quad (4.2)$$

³ImageNet[20]で訓練されたオリジナルのモデルからさらにImageNetに含まれないような顔画像データなどのLaion-Humans, LAION-Aesthetics[21]によってチューニングされている。

これらのパラメータを使用してタイムステップに応じたノイズが付与される。これは式 (4.3) で表される通り、潜在画像 z_0 と完全なガウシアンノイズ ϵ を、タイムステップ t における $\sqrt{\bar{\alpha}_t}$ と $\sqrt{1 - \bar{\alpha}_t}$ の値に応じて足し合わされる。

$$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \quad (4.3)$$




図 4.5: β の線形スケジューリング (左上) による α (上中央), $\bar{\alpha}$ (右上), $\sqrt{\bar{\alpha}_t}$ (左下), $\sqrt{1 - \bar{\alpha}_t}$ (右下) の変化

モデルにはノイズ画像 z_t とタイムステップ t , クラスラベル y を入力として与える。訓練の目的は、式 (6.18)⁴ の ELBO を最大化することである。より簡略化して損失関数を示すと式 (4.4) で表せる。式 (6.18) の第二項には学習可能なパラメータはなく、ほぼ 0 に等しいため損失関数には加えない。

$$L(\theta) = -\log p_\theta(x_0|x_1) + \sum_{t=2}^T D_{KL}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t)) \quad (4.4)$$

q と p_θ はともに、ガウス分布を想定しており、KL ダイバージェンスは2つの分布の平均と共分散で評価することが可能である。ノイズパラメタライズ拡散モデ

⁴ $\mathbb{E}_{q(x_1|x_0)} [\log p_\theta(x_0|x_1)] - D_{KL}(q(x_T|x_0) || p(x_T)) - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)} [D_{KL}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t))]$

ル⁵のKLダイバージェンス項は式(6.26)⁶で示せることから係数を排除して式(4.5)の L_{mse} で表せられる.

$$L_{mse} = \| \epsilon - \epsilon_\theta(\sqrt{\alpha_t}z_0 + \sqrt{1 - \alpha_t}\epsilon, t) \|^2 \quad (4.5)$$

しかし、逆拡散プロセスでの共分散 Σ_θ をフルに学習して拡散モデルを学習させるためには、KLダイバージェンス項を最適化するため、Nichol と Dhariwal のアプローチ [22] に従い、 ϵ_θ を L_{mse} で学習し、 Σ_θ を $L(\theta)$ をフルに使用して学習する.

Sampling

Algorithm 2 Sampling: PyTorch pseudo code

```

1 label = [0,0,1,1]
2 n = len(label)
3 z_t = torch.randn((n, 4, 32, 32))
4
5 for t in [1000, 999, ..., 2, 1]:
6     output = model(z_t, t, label)
7     e = torch.randn_like(z_t)
8     z_{t-1} = \frac{1}{\sqrt{\alpha_t}}(z_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}}output) + \sigma_t \cdot e
9     z_t = z_{t-1}
10 samples = D(z_t)
```

サンプリングは、純粋なガウシアンノイズからクラスラベルという条件を付与しながらノイズを除去していく過程のことである。 z_t から z_{t-1} のデノイズ (式(4.6)) を、タイムステップ $t = 1000$ から $t = 1$ まで繰り返し、ノイズが完全に除去された画像を生成する.

$$z_{t-1} = \frac{1}{\sqrt{\alpha_t}}(z_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}}\epsilon_\theta) + \sigma_t \cdot \epsilon \quad (4.6)$$

デノイズされた潜在画像を訓練時に使用していた VAE エンコーダとセットで訓練された VAE デコーダを使ってピクセル空間の画像を得ることができる.

⁵ノイズを予測して訓練される拡散モデルのこと. これに対して元画像を予測して訓練される拡散モデルをイメージパラメタライズ拡散モデルと呼んでいる. 詳細は付録で示す.

⁶ $\arg \min_\theta D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t)) = \arg \min_\theta \frac{(1-\alpha_t)^2}{2\sigma_q^2(t)(1-\bar{\alpha}_t)\alpha_t} \left[\|\epsilon_0 - \hat{\epsilon}_\theta(x_t, t)\|_2^2 \right]$

4.2 潜在拡散モデルでの表現学習

大規模なラベルなしデータセットを使用して事前学習させたモデルを、解きたいタスクに合わせた少量のデータセットを使用してチューニングし、目的に合った高性能なモデルを得るというプロセスを拡散モデルで構築しようと考えた。このプロセスを「拡散モデルを用いた表現学習」と呼ぶことにする。我々は、このアプローチを提案する。

事前学習ということを考慮し、ラベルなしで利用できる無条件潜在拡散モデルと、表現条件付き潜在拡散モデルを設定した。これらを訓練し、ダウンストリームタスクとして分類問題を解くことを考える。事前学習済みモデルの重みパラメータをクラス条件付き潜在拡散モデルへロードし、ファインチューニングを行い、そのモデルからのゼロショットクラス分類手法⁷を用いて分類結果を得る。

4.2.1 無条件潜在拡散モデルを使用した画像の表現学習

図 4.6 は、図 4.4 のアーキテクチャからラベル y をインプットしないよう改良し




図 4.6: 無条件潜在拡散モデル

⁷クラス条件付き拡散モデルからクラス分類子を取り出す手法。詳細はセクション 5.2.

た条件なしの潜在拡散モデルである。

Pre-training

事前学習として，潜在空間上で無条件拡散モデルをトレーニングする．訓練の目的はクラスラベル条件付き潜在拡散モデルと同じであり， ϵ_θ を L_{mse} ， Σ_θ を $L(\theta)$ で訓練する．

Fine-tuning

クラスラベル条件付き潜在拡散モデル (図 4.4) に対して無条件潜在拡散モデルの事前学習済み重みパラメータをロードし，クラスラベルを条件付けとして与えながら，ファインチューニングを行う．

4.2.2 表現条件付き潜在拡散モデルを使用した画像の表現学習

図 4.7 は、潜在拡散モデル内にビジョントランスフォーマー (ViT)[19] を組合せ、




図 4.7: 表現条件付き潜在拡散モデル

明示的に表現を組み込んだ拡散モデルである。ViT へのインプットサイズは $32 \times 32 \times 4$ であり、パッチサイズを 2、埋め込み次元を 768 に設定しているため、表現 r の次元は 256×768 である。その表現は、2 か所に渡される。一つが、Norm 層、Linear 層、UnPatchify 層を通り $32 \times 32 \times 4$ の次元になった表現と、デノイズアーキテクチャに入力される $32 \times 32 \times 4$ の画像を結合し、 $32 \times 32 \times 8$ の次元でデノイズアーキテクチャに渡される。もう一つが、 256×768 の次元のまま、デノイズアーキテクチャに N 個⁸存在するブロックの先頭に結合され、 256×1536 の形になり、Linear 層を 1 つ設け 256×768 の次元でブロック内部に処理が進む。

VAE での潜在空間上で ViT にエンコードされた画像表現をデノイズ時に渡す、この処理が表現を条件付けるということであり、サンプリング時に生成したい画像を表現によって制御することが可能になる。

⁸DiT B では $N=12$

Pre-training

事前学習は、VAE 潜在空間上で、ViT でエンコードされた画像表現を与えながらトレーニングされる。ViT も同時に訓練されるため、デノイズで条件付けられる表現はトレーニングが進むにつれて拡散モデルの条件として最適化されていく。損失関数は無条件潜在拡散モデルと同様である。

Fine-tuning

無条件でのアプローチと同様に、クラスラベル条件付き潜在拡散モデル (図 4.4) に対して、表現条件付き潜在拡散モデルの事前学習済み重みパラメータをロードし、クラスラベルを条件付けとして与えながらファインチューニングを行う。事前学習時、ノイズ画像と表現を結合し、チャンネルを 2 倍にしてデノイズアーキテクチャにインプットしていたため、ロード時にはノイズ画像部分を受容するパラメータのみロードする。また、表現を結合していたブロック手前部分に関しても、一つ設けた Linear 層を無視することでパラメータ数の異なるモデルへのロードに対処した。

第5章 実験結果

第5章では、本研究の実験について述べる。5.1節では、データセットに関して述べる。5.2節では、クラス条件付き潜在拡散モデルからクラス分類子を取り出す手法について述べる。5.3節では、ベースラインの DiT を使用して脳画像を生成した結果について述べる。5.4節では、本論文で提案する表現条件付き潜在拡散モデルの評価結果と、そのモデルから得られた画像表現を用いた分類結果について述べる。

5.1 データセット

本研究では、脳画像データセットを使用して実験を行っている。画像データは CT スキャンのスライスであり、スライス画像のサイズは 512×512 ピクセル、データは DICOM 形式で保存されており、ピクセル値の単位はハウズフィールド単位 (HU) である。本研究においては、先行研究 [23] での前処理が行われたアノテーションデータセットを使用した。

実験に使用した CT 画像アノテーションデータセットでは、血腫領域のアノテーション（セグメンテーション用）、血腫マーカーの種類のアノテーション (hypodensities, margin irregularity, blend sign, fluid levels)、血腫の矩形領域のアノテーション（血腫領域より導出）、側脳室前角と側脳室後角および正中線の交差する点などのアノテーションがある。

血腫マーカーの種類は、は Boulouis et al. [24] が提案した hypodensities, margin irregularity, blend sign, fluid levels の4つの血腫マーカークラスがある。なおこれらのマーカーはそれぞれ独立で重複可能である。本研究では、主に血腫の有無に着目しているため4つの血腫マーカーのいずれかが存在すれば血腫である、いずれも存在しなければ血腫ではないというアノテーションを設定した。

表 5.1: 事前学習とダウンストリームタスクに使用する CT 画像のデータ数

purpose	hospital number	data quantity
pre-training	2-12	10,313
downstream task	1	1,781

表 5.2: ダウンストリームタスクに使用する CT 画像の用途別データ数

type	data quantity
training data	1,424
validation data	178
test data	179
all	1,781

データの分割

CT スキャンは 12 の施設から収集しており，そのうちの 2 から 12 を事前学習用のデータ，1 をダウンストリームタスク用のデータと設定した．データ数は表 5.1 で示す．また，ダウンストリームタスク用のデータはさらに，訓練データ，検証データ，テストデータに 8:1:1 で分割した (表 5.2)．

5.2 血腫分類

拡散モデルは内部の情報をノイズとして扱っているため，直接的な表現は存在せず，拡散モデルを表現を出力するエンコーダと捉えることは困難であると考えられる．そこで，クラス分類に関して Alexander et al.[25] が提案した拡散分類器 (Diffusion Classifier) を参考にする．これは，クラスラベル条件付けの拡散モデルに対して，すべてのラベルを条件付けとして渡し，出力されるノイズと本来のノイズの平均二乗誤差が最も小さいとき最適なクラスと判断するというものである．出力されたノイズ ϵ_θ とモデルに入力するノイズ画像 z_t から，タイムステップ $t=0$ の元画像を予測した z'_0 を得ることが可能である (式 (5.1))．このことを利用して，本実験では，予測した元画像と本来の元画像との平均二乗誤差を測る．このイメージを図 5.1 で示す．

$$z'_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}(z_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_\theta) \quad (5.1)$$




図 5.1: 拡散モデル分類器

この手法は、どのタイムステップ t を選択するのが最適か明確に決まっていないという欠点がある。我々が構築した拡散モデルは総タイムステップ数 $T = 1,000$ を想定しており、その時間に応じて拡散モデルが示す挙動は異なる。 $t = 1,000$ に近ければ、99.9%以上がノイズ情報であり元画像の情報はほぼ失われていると思われる。また $t = 0$ に近ければ、99.9%以上が元画像の情報であり、潜在空間上でどれだけ元画像に近づけられるかを考えている。つまりこのあたりで、画像表現を学習しているとは思えない。 $t = 200$ から 400 あたりの時間は、ノイズと画像のどちらの情報も適度にあり、これをデノイズすることを拡散モデルは学習するため、画像表現を強く学習していると思われる。経験上 $t = 200$ から 400 あたりで分類精度が高いと思われる。現状、どの時間がクラス分類に最適かは貪欲に総当たりするしか方法がない。

生成モデルの評価方法

FID, sFID, IS, Precision, Recall の5つの指標で評価を行う。これらの計算のために ImageNet で学習された Inception-v3[26] モデルを使用する。

- **FID(Frechet Inception Distance):** 実際の画像と生成された画像の間の特徴距離を測定するための評価指標である。小さいほど良いモデルと考えられる指標である。
- **sFID(spatial Frechet Inception Distance):** Nash et al.[27] が提案した FID の派生指標である。sFID は Inception-v3 から得られる2つの特徴を使

用して計算される。1つは、FID の計算に使用される標準の 'pool3:0' からの特徴であり、もう1つは、 'mixed_6/conv:0' から7チャンネル分の特徴である。この2つを使用してFID 導出と同様の計算で導出される。後者を含める理由は、モデル間の空間分布の類似性の感覚を提供するためであり、空間的な違いを考慮している。

- **IS(Inception Score):**Inception-v3 による分類精度で画像の質を測り、すべての画像の分類結果数のエントロピーから多様性を測る。この値は高いほど、生成される画像の質と多様性が保証される。ただ、Inception-v3 は ImageNet を使用して訓練されているため、本実験で使用する CT スライス画像を入力すると正しい結果が得られないと思われる。
- **Precision:**Inception-v3 での分類結果が使用される。元データでの分類結果とサンプリングデータでの分類結果の適合率を表す。
- **Recall:**Inception-v3 での分類結果が使用される。元データでの分類結果とサンプリングデータでの分類結果の再現性を表す。

これらの指標で評価するにあたり、少なくとも 10,000 枚のデータ数が推奨されているため、我々の実験でも 10,000 のサンプルを生成して事前学習用のデータセットと比較する。

5.3 拡散トランスフォーマー (DiT) を使用した画像生成

ベースラインとして設定した DiT を使用し、脳画像の生成を行う。

Training

事前学習用データを使用してクラス条件付潜在拡散モデルである DiT のトレーニングを行う。損失の推移は図 5.2 の通りである。横軸の training steps はデータローダー 1 バッチの処理ごとに加算される数値を表す。¹

本実験で使用したモデルは DiT B モデルであり、B は Base の略称でモデルの大きさを表す。DiT が提供しているモデルの大きさは S, L, B, XL の 4 種類ある。モデルの大きさは主に、埋め込み次元、ブロック数、マルチヘッドアテンション

¹例えば、今回使用したデータ数は 10,313、バッチサイズは 32 を設定したため、1 epoch あたり training step は 322 ($\div 10,313 \div 32$) である。この実験では 1,400 epochs 回しているため、training steps はおよそ 450,800 ($= 322 \times 1,400$) である。




図 5.2: 事前学習用データを使用した DiT トレーニング時の損失の推移

のヘッド数の 3 つのパラメータを制御している (表 5.3). B は埋め込み次元が 768, ブロック数が 12, ヘッド数が 12 である. 画像のサイズは 256 にリサイズし, パッチサイズは 2, クラス数は 2 と設定して訓練している.

表 5.3: DiT モデルの詳細 [10].

Model	Blocks	Hidden size	Heads	Gflops
S	12	384	6	1.4
B	12	768	12	5.6
L	24	1,024	16	19.7
XL	28	1,152	16	29.1

Sampling

seed 値を 0 に設定し, クラスラベル 0, 1 に関してそれぞれ 16 枚ずつ生成した画像を図 5.3, 5.4 で示す.




図 5.3: クラスラベル 0 で条件付けして生成した画像




図 5.4: クラスラベル1で条件付けして生成した画像

図 5.3 は，クラスラベル 0 を条件として与えて生成した画像 16 枚である．クラスラベル 0 は血腫がないことを意味しているため，ほとんどの画像において血腫は見当たらない．3 行 2 列目の画像は側脳室²に血腫のような灰色のものが 2 つ確認できる．これはうまく生成できていない例である．

図 5.4 は，クラスラベル 1 を条件として与えて生成した画像 16 枚である．血腫のような灰色のものが見られ一見うまく生成できているように感じる．しかし一

²頭蓋内中心の暗いところ

部は血腫の形が大きすぎたり，側脳室の形に沿って血腫があったりなど血腫画像として正常とは言えない画像が生成されていることが確認できる．

5.4 潜在拡散モデルでの表現学習

Pre-training

事前学習用データを使用して，無条件潜在拡散モデルと表現条件付き潜在拡散モデルのトレーニングを行う．それぞれの損失の推移は図 5.5 の通りである．




図 5.5: 無条件潜在拡散モデルと表現条件付き潜在拡散モデルのトレーニング時の損失の推移

この損失の値は，式 (4.5)³ のノイズ平均二乗誤差 L_{mse} と，式 (4.4)⁴ の $L(\theta)$ との和であり，後者はノイズ平均二乗誤差 L_{mse} より 10^{-3} スケールほど小さく，主な訓練の目的はノイズ平均二乗誤差 L_{mse} である．

無条件の方は，クラス条件付き潜在拡散モデルでの損失の推移 (図 5.2) と類似しており，0.35 あたりから始まって 0.05 あたりまで下がっていることが見て取れる．しかし表現条件付きの方は，階段のようにある値を超えると急激に落ちるような下がり方をしている．この原因は不明だが，他 2 つと違う点は，モデル内に表現

³ $L_{mse} = \| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t}z_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t) \|^2$

⁴ $L(\theta) = -\log p_{\theta}(x_0|x_1) + \sum_{t=2}^T D_{KL}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t))$

にエンコードする ViT が組み込まれており，その ViT パラメータが更新されると拡散モデルに条件付けられる画像表現が変化するため，それが損失を階段状にする要因ではないかと思われる．また，損失がかなり小さく下がっており，これは表現を条件付けて渡すことでノイズ画像から表現という元画像情報を得られるため出力すべきノイズの予測が容易になっているためだと考えられる．

訓練におけるハイパーパラメータは，表 5.4 の通りである．使用しているデータ数とモデルの大きさ，GPU の容量などを考慮しバッチサイズを 16 に設定した．

DiT[10] で行われた実験からは，トレーニングステップが増えるほど FID が小さくなり，生成モデルとしての性能が良いという結果が得られていた．バッチサイズが小さいほどデータローダのバッチ数が多くなるため，トレーニングステップは多くなる．本実験では，エポック数を 1,000 に設定してあるが，バッチサイズと考慮してもトレーニングステップ数は 600,000 ほどであり，この値は DiT[10] では十分な性能が得られていたためこの値に設定した．

モデルサイズの B はモデル内部のパラメータを制御しており (表 5.3)，埋め込み次元 768，ブロック数 12，ヘッド数 12 を表す．実験の効率を考慮し B に設定した．

表 5.4: 事前学習でのハイパーパラメータの値

epochs	1,000
batch size	16
model size	B
image size	256
patch size	2
learning rate	1e-4

Sampling

生成モデルの性能評価として表 5.5 を示す．それぞれのモデルで 10,000 の画像をサンプリングし評価した．元データと生成データの分布を比較したものが FID，sFID である．小さいほど良いとされるが，表現を条件付けで訓練させたモデルは，他と比べて小さい値であり，これは表現という元画像情報をサンプリング時に与えていることで元画像に似た画像を生成することができ，データ分布が元データセットの分布に近づいたためこの結果になったと考えられる．IS は生成したデータ分布の多様性や質を測る指標であり大きいほど良いとされるが，この値を出す

際に使用されたモデルが ImageNet で学習されているため、多様性という点で脳画像ばかり生成しているデータ分布は低く算出されていると考えられる。

表 5.5: 事前学習用データを使用して訓練した条件別潜在拡散モデルの評価結果

Conditions	FID	sFID	IS	Precision	Recall
Class Label	25.69	21.57	<u>3.257</u>	0.39	0.36
None	24.42	20.98	3.117	0.40	0.39
Representation	<u>10.00</u>	<u>12.20</u>	3.204	<u>0.94</u>	<u>0.99</u>



図 5.6: 事前学習用データの分布と条件別生成データの分布




図 5.7: 事前学習用データの分布とモード崩壊時に想定される分布例




図 5.8: 事前学習用データの分布と生成データの分布との比較. (左) クラス条件付き, (中央) 無条件, (右) 表現条件付き.

図 5.6 は、画像データの分布を表している。横軸がデータが分布する範囲を表し、縦軸がその範囲 (離散値) に存在するデータ数を表す。これらの図は、FID や

ISなどを計測する際に使用した Inception-v3[26] モデルを用いて、出力した特徴表現 (2,048 次元) を t-SNE[28] を用いて 1 次元に圧縮，離散値に丸め込み，その個数をプロットしたものである。

図 5.7 は生成モデルがモード崩壊を起こした際に起こりうるサンプル例を示したものである。モード崩壊とは，特に GAN における訓練で遭遇する問題であり，生成モデルが生成した画像の多くが，複製 (モード) を含み，変化に乏しい画像ばかりを生成してしまうことである。元データ分布では横軸の値が 5 の時におよそ 1,400 枚で最も多くデータが分布している。生成モデルは，それに似た画像を生成することばかりに囚われ，横軸 5 の値の画像ばかり生成してしまった例を示している。

図 5.8 は図 5.6 を条件ごとに分けて表示した図であり，本実験で訓練した潜在拡散モデルはどれもモード崩壊を起こしておらず，多様性のある生成ができていることが分かる。図 5.8 右の表現条件付きで生成された画像の分布は元データセットの分布と類似しており，FID の値を裏付ける分布になっていることが分かる。




図 5.9: 表現条件付き潜在拡散モデルでのサンプリング例

図 5.9 は，表現条件付き潜在拡散モデルのサンプリングの例である。左の画像が

元画像であり，この画像からエンコードされた表現を条件に右の4枚を生成した．違いが分からないほどに生成できていると思われる．

Fine-tuning

事前学習で得られた無条件または表現条件付きの潜在拡散モデルの事前学習済み重みパラメータをクラス条件付き潜在拡散モデルにロードする．このモデルをダウンストリーム用のデータを使用してクラスラベルでの条件を与えながらファインチューニングを行った．




図 5.10: タイムステップ t におけるノイズ画像とそれを入力としてクラス条件を与えながら生成した画像例

図 5.10 は，ファインチューニングしたクラス条件付き潜在拡散モデルを使用し，タイムステップ t におけるノイズ画像からクラスラベルを条件付けながら t 回デノ

イズして得られた結果である。

例えば、 $t = 500$ を見ると、元画像 ($t = 0$ の一番左) に対して、 $t = 500$ におけるノイズ画像が一番左の画像であり、骨の形が薄くわかる程度である。その画像を拡散モデルに入力し、右4枚のうち左2枚がクラスラベル0を条件付けながら、右2枚がクラスラベル1を条件付けながら、500回デノイズして得られた画像である。左2枚は元画像にあるはずの血腫が消えており、右2枚は血腫の位置が変わっているものもあるが、血腫が明確にわかる程度に生成されている。

この実験の意図することは、元画像の情報を壊しすぎずクラスラベルによる条件付けがうまく制御できるかを調べることである。タイムステップ t に応じて結果が異なることが分かる。 $t \leq 200$ では、元画像情報が残りすぎたために、クラスラベルによる条件付けが制御できていない。 $300 \leq t \leq 600$ では、元の脳の形を維持しながら血腫の有無を制御できている。 $700 \leq t$ では、ノイズが強すぎるため元画像情報を無視してクラスラベルのみで条件付けられたような画像を生成している。




図 5.11: 純粋なノイズから画像をデノイズする過程 (上) とそのノイズからの元画像予測 (下)

図 5.11 は、上 3 つが無条件潜在拡散モデル、下 3 つが表現条件付き潜在拡散モデルでのサンプリングプロセスである。それぞれの上段が純粋なノイズから画像をサンプリングする過程、下段が上の画像から完全にデノイズされた画像を予測したものである。無条件の方は $t > 600$ のノイズが多い画像からデノイズ後画像を正確に予測できておらず、ぼかしがかかっている。一方表現条件付きの方は、 $t = 800$ 時点でデノイズ後画像を予測できているように見て取れる。

この元画像予測の違いが、無条件潜在拡散モデルと表現条件付き潜在拡散モデルの違いであると思われる。クラス条件付き潜在拡散モデルから分類子を抽出する際に使用するはこの元画像を予測した画像であり、この予測画像と元画像との平均二乗誤差の大小で分類するため、元画像を予測する精度が高いほど分類精

度も高くなると考えられる。

クラス条件付き潜在拡散モデルからのゼロショット分類により、血腫分類を行う。任意のタイムステップ t から $t-1$ のデノイズを行う際に、データ数が多いほど、デノイズ時のランダム性に左右されず正確な結果が得られるため、本実験ではクラスラベル 0, 1 それぞれ 512 の計 1,024 のバッチサイズでデノイズプロセスを行う。クラスラベル 0, 1 でそれぞれ平均二乗誤差は 512 個だけ得られ、その平均の大小を比較をする。事前学習に無条件、表現条件付きで訓練された潜在拡散モデルのそれぞれの分類結果 (accuracy, F-score) を図 5.12, 5.13 で示す。




図 5.12: タイムステップごとの分類結果（事前学習：無条件）




図 5.13: タイムステップごとの分類結果（事前学習：表現条件付き）

図 5.12 は，事前学習時に無条件で訓練させたモデルを使用してクラスラベル条件付き潜在拡散モデルをダウンストリーム用データでファインチューニングしたモデルの分類結果である． $t = 230$ で F 値が最大となった．

また，図 5.13 は，事前学習時に表現で条件付けながら訓練した場合の分類結果である． $t = 450$ で F 値が最大となった．まとめた結果を表 5.6 に示す．

表 5.6: ダウンストリーム用テストデータを使用した血腫分類結果

Pre-training	Classification	Accuracy	F-score	Recall	Precision
None	ResNet50	0.7150	0.4950	<u>0.8928</u>	0.3424
None	ViT B	0.8659	0.5200	0.4642	0.5909
DINOv2	Linear	0.8882	0.6875	0.7857	0.6111
無条件 DiT	zero-shot	0.8882	0.7058	0.8571	0.6000
表現条件付き DiT	zero-shot	<u>0.9497</u>	<u>0.8235</u>	0.7500	<u>0.9130</u>

表現で条件付けして事前学習した潜在拡散モデルの分類結果が最も高パフォーマンスといえる．我々が提案する潜在拡散モデルを用いた手法はどちらも，DINOv2 を，Accuracy・F-score とともに上回る結果が得られた．

第6章 結論

本論文では、まず、変分オートエンコーダで圧縮された潜在空間上で動作するトランスフォーマーベースの拡散モデル (DiT) を用いて、脳 CT 画像の生成を試みた。

次に、DiT 内部に画像表現をエンコードするビジョントランスフォーマーアーキテクチャを組み込み、表現で条件付けられた画像生成モデルを提案した。このモデルで生成したサンプルはオリジナルの DiT と比較すると、FID が 15.69 向上することを示した。

最後に、自己教師あり表現学習として、拡散モデルを使用した手法を提案した。このアプローチでの分類結果は Accuracy が 6.15%, F 値が 13.6%, DINOv2 を上回ることを示した。

今後の課題として、次の3つを挙げる。

1つ目に、モデルサイズを変更して実験を行うことである。本実験では、B サイズを選択して結果を得たが、DiT[10] で行われた実験ではモデルサイズが大きいほど FID が下がるという結果が出ていたため、S, L, XL のモデルサイズで訓練を行い、その結果を比較しようと考えている。

2つ目に、データセットを変更して実験を行うことである。本実験では、脳 CT 画像データを使用して結果を得ており、分類結果の向上が脳画像のみに現れるものか一般的な自然画像にも適用可能なのかを実験で確かめたいと考えている。

3つ目に、脳の個人差を考慮することである。CT スキャンのスライス画像は本来個人ごとに頭の上部から下に向かって撮像される。そのため脳画像は個人の時系列データと考慮することができる。本実験ではスライスをシャッフルして個人差などを考慮せずデータを扱ったため、個人をラベル付けた番号を設定しその値で条件付けて脳画像を生成したり、個人差によって分類結果がどのように変化するかを実験で確かめたいと考えている。

参考文献

- [1] Aaron Van Den Oord, Oriol Vinyals, et al. Neural discrete representation learning. *Advances in neural information processing systems*, Vol. 30, , 2017.
- [2] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In *International Conference on Machine Learning*, pp. 8821–8831. PMLR, 2021.
- [3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pp. 8748–8763. PMLR, 2021.
- [4] Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu, and Mark Chen. Hierarchical text-conditional image generation with clip latents. *arXiv preprint arXiv:2204.06125*, Vol. 1, No. 2, p. 3, 2022.
- [5] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- [6] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 10684–10695, 2022.
- [7] Florian Bordes, Randall Balestriero, and Pascal Vincent. High fidelity visualization of what your self-supervised representation knows about. *arXiv preprint arXiv:2112.09164*, 2021.
- [8] Jeremias Traub. Representation learning with diffusion models. *arXiv preprint arXiv:2210.11058*, 2022.

- [9] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 9650–9660, 2021.
- [10] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv preprint arXiv:2212.09748*, 2022.
- [11] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *arXiv preprint arxiv:2006.11239*, 2020.
- [12] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. *arXiv preprint arXiv:1911.05722*, 2019.
- [13] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pp. 1597–1607. PMLR, 2020.
- [14] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhao-han Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent—a new approach to self-supervised learning. *Advances in neural information processing systems*, Vol. 33, pp. 21271–21284, 2020.
- [15] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [16] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised learning of visual features by contrasting cluster assignments. *Advances in neural information processing systems*, Vol. 33, pp. 9912–9924, 2020.
- [17] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. ibot: Image bert pre-training with online tokenizer. *arXiv preprint arXiv:2111.07832*, 2021.

- [18] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, Vol. 30, , 2017.
- [19] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [20] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In F. Pereira, C.J. Burges, L. Bottou, and K.Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, Vol. 25. Curran Associates, Inc., 2012.
- [21] Romain Beaumont. img2dataset: Easily turn large sets of image urls to an image dataset. <https://github.com/rom1504/img2dataset>, 2021.
- [22] Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, pp. 8162–8171. PMLR, 2021.
- [23] Hokuto Hirano and Tsuyoshi Okita. Classification of hematoma: Joint learning of semantic segmentation and classification. *arXiv preprint arXiv:2103.17172*, 2021.
- [24] Gregoire Boulouis, Andrea Morotti, H Bart Brouwers, Andreas Charidimou, Michael J Jessel, Eitan Auriel, Octávio Pontes-Neto, Alison Ayres, Anastasia Vashkevich, Kristin M Schwab, et al. Association between hypodensities detected by computed tomography and hematoma expansion in patients with intracerebral hemorrhage. *JAMA neurology*, Vol. 73, No. 8, pp. 961–968, 2016.
- [25] Alexander C Li, Mihir Prabhudesai, Shivam Duggal, Ellis Brown, and Deepak Pathak. Your diffusion model is secretly a zero-shot classifier. *arXiv preprint arXiv:2303.16203*, 2023.
- [26] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2818–2826, 2016.

- [27] Charlie Nash, Jacob Menick, Sander Dieleman, and Peter W. Battaglia. Generating images with sparse representations. *ArXiv*, Vol. abs/2103.03841, , 2021.
- [28] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, Vol. 9, pp. 2579–2605, 2008.
- [29] Calvin Luo. Understanding diffusion models: A unified perspective. *arXiv preprint arXiv:2208.11970*, 2022.
- [30] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, Vol. 33, pp. 6840–6851. Curran Associates, Inc., 2020.
- [31] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily L Denton, Kamyar Ghasemipour, Raphael Gontijo Lopes, Burcu Karagol Ayan, Tim Salimans, et al. Photorealistic text-to-image diffusion models with deep language understanding. *Advances in Neural Information Processing Systems*, Vol. 35, pp. 36479–36494, 2022.

付録

本論文で扱う内容に関する基礎知識を付録としてまとめた。以下、ELBO、変分オートエンコーダ、拡散モデルに関する内容は'Understanding Diffusion Models: A Unified Perspective'[29]を参考にまとめたものである。

ELBO

数学的には、潜在変数 z と我々が観測するデータ x は、同時分布 $p(x, z)$ によってモデル化されると想像できる。尤度ベースと呼ばれる生成モデリングの1つのアプローチは、すべての観測されたデータの尤度 $p(x)$ を最大化するモデルを学習することである。純粋な観測データの尤度 $p(x)$ を復元するために、この同時分布を操作する方法が2つある。一つは、式 (6.1) にあるように潜在変数 z を明示的に周辺化する方法である。

$$p(x) = \int p(x, z) dz \quad (6.1)$$

$$p(x) = \frac{p(x, z)}{p(z|x)} \quad (6.2)$$

もう一つは、式 (6.2) の確率の連鎖法則を用いる方法だ。尤度 $p(x)$ を直接計算し最大化することは、式 (6.1) においては、すべての潜在変数 z を積分する必要がある複雑なモデルでは困難。式 (6.2) においても、真に正しいといえるエンコーダ $p(z|x)$ を知り得る必要があるため、困難である。

ここで、エビデンスの下界である Evidence Lower Bound(ELBO) というものを考える。エビデンスとは、観測データの対数尤度として定量化され、 $\log p(x)$ で表される。ELBO は式 (6.3) で表される。

$$\begin{aligned} \log p(x) &\geq ELBO \\ &= \mathbb{E}_{q_\phi(z|x)} \left[\frac{p(x, z)}{q_\phi(z|x)} \right] \end{aligned} \quad (6.3)$$

式 (6.3) の $q_\phi(z|x)$ は、パラメータ ϕ を持つ柔軟な近似変分であり、我々が最適化しようとする分布である。一般に、我々はエビデンスの下界である ELBO を最

大化することを目的としているが、この式からはその意図がわかりにくい。エビデンスと ELBO の関係を掘り下げる。

$$\begin{aligned}
\log p(x) &= \log p(x) \cdot 1 \\
&= \log p(x) \cdot \int q_\phi(z|x) dz \\
&= \int q_\phi(z|x) (\log p(x)) dz \\
&= \mathbb{E}_{q_\phi(z|x)} [\log p(x)] \\
&= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{p(z|x)} \right] \\
&= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{p(z|x)} \cdot \frac{q_\phi(z|x)}{q_\phi(z|x)} \right] \\
&= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{q_\phi(z|x)} \right] + \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{q_\phi(z|x)}{p(z|x)} \right] \\
&= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{q_\phi(z|x)} \right] + D_{KL}(q_\phi(z|x) || p(z|x)) \quad (6.4) \\
&\geq \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{q_\phi(z|x)} \right] \quad (6.5)
\end{aligned}$$

式 (6.4) から、エビデンスが ELBO に近似事後分布 $q_\phi(z|x)$ と真の事後分布 $p(z|x)$ 間の KL ダイバージェンスを加えたものであることがわかる。この KL ダイバージェンス項は非負であるため、式 (6.5) が導出されている。式 (6.4) に注目すると、エビデンスと ELBO の差は厳密に KL ダイバージェンス項であることは明白だろう。

ELBO を最大化する意味について考察する。モデル化したい潜在変数 z を導入した我々の目的は、観測データを記述する潜在的な構造を学習することであり、変分事後分布 $q_\phi(z|x)$ のパラメータ ϕ を最適化し、真の事後分布 $p(z|x)$ に正確に一致させることである。これは、式 (6.4) の KL ダイバージェンス項を最小化することと同義である。しかし、我々は真に正しい $p(z|x)$ の分布を知り得ることは不可能であり、KL ダイバージェンス項を直接最小化することは困難である。ここで、左辺の対数尤度（エビデンス）について考えてほしい、これは我々が最適化したいパラメータ ϕ に依存していない。つまり、求めたいエビデンスは変数 ϕ について常に定数であり、ELBO を ϕ に関して最大化すると、必然的に KL ダイバージェンス項が等しく最小化されることになる。したがって、ELBO は真の潜在的な事後分布を完全にモデル化する方法を学習するために、代理として最大化する目的関数とすることができる。

変分オートエンコーダ




図 6.1: VAE のグラフィカルモデル. エンコーダ $q(z|x)$ は観測値 x の潜在変数 z にわたる分布を定義し, $p(x|z)$ は潜在変数 z を観測値 x に渡すデコーダを表す.

変分オートエンコーダ (VAE)[5] のデフォルトの定式化では, ELBO を直接的に最大化することで訓練される. ϕ によってパラメータ化された潜在的な事後分布の中から最も良い $q_\phi(z|x)$ に最適化する. この関係を明示するために, ELBO 項をさらに分解する.

$$\begin{aligned}
 ELBO &= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(x, z)}{q_\phi(z|x)} \right] \\
 &= \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p_\theta(x|z)p(z)}{q_\phi(z|x)} \right] \\
 &= \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] + \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(z)}{q_\phi(z|x)} \right] \\
 &= \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) || p(z)) \quad (6.6)
 \end{aligned}$$

ここでの $q_\phi(z|x)$ はエンコーダとして扱うことができ, 入力を潜在変数がとりうる値の分布に変換する. 同時に決定論的関数 $p_\theta(x|z)$ を学習し, 与えられた潜在ベクトル z を観測値 x に変換するが, これはデコーダと解釈される.

式 (6.6) の 2 項はそれぞれ直感的に説明できる. 第一項は我々の変分分布 $q_\phi(z|x)$ からデコーダ $p_\theta(x|z)$ の再構成された尤度を測定する. 第二項は, 学習された変分分布 $q_\phi(z|x)$ が潜在変数に関する事前信念 $p(z)$ にどれだけ似ているかを測定する. したがって, ELBO を最大化することは, その第一項を最大化し, 第二項を最小化することと等価である.

VAE の特徴は, パラメータ ϕ, θ に対して同時に ELBO を最適化するということだ. 一般的に, VAE のエンコーダには対角共分散を持つ多変量ガウシアンをモ

デル化し、事前信念には標準的な多変量ガウシアンが用いられることが多い。

$$q_\phi(z|x) = N(z; \mu_\phi(x), \sigma_\phi^2(x)I)$$

$$p(z) = N(z; 0, I)$$

目的関数は式 (6.7) のように表せる。

$$\begin{aligned} L &= \arg \max_{\phi, \theta} ELBO \\ &= \arg \max_{\phi, \theta} \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) || p(z)) \end{aligned} \quad (6.7)$$

ここで、KL 項は解析的に計算され、再構成項は、モンテカルロ推定を用いて期待値を近似することで計算できる。我々の目的関数は式 (6.8) のように書き換えられる。

$$L = \arg \max_{\phi, \theta} \sum_{l=1}^L \log p_\theta(x|z^{(l)}) - D_{KL}(q_\phi(z|x) || p(z)) \quad (6.8)$$

潜在変数 $\{z^{(l)}\}_{l=1}^L$ は、データセット中のすべての観測 x に対して $q_\phi(z|x)$ からサンプリングされる。しかし、我々の損失が計算される各 $z^{(l)}$ は確率的サンプリング手順で生成され、それは一般的に微分不可能である。そこで、再パラメータ化トリックによって誤差逆伝播を可能にした。

再パラメータ化トリックとは、ランダムな変数をノイズ変数の決定論的関数に書き換えることである。例えば、任意の平均 μ と分散 σ^2 を持つ正規分布 $x \sim N(x; \mu, \sigma^2)$ からのサンプルは $\epsilon \sim N(\epsilon; 0, I)$ を用いて式 (6.9) で表せる。

$$x = \mu + \epsilon\sigma \quad (6.9)$$

つまり、任意のガウス分布は、その平均を 0 から目標の平均 μ に加算シフトし、分散を目標の分散 σ^2 だけ伸ばした標準ガウス分布と解釈することができる。したがって、再パラメータ化トリックにより、任意のガウス分布からのサンプリングは、標準ガウス分布からサンプリングし、そのサンプルを目標の標準偏差、平均でスケール、シフトすることで得られる。

VAE では、式 (6.10) のように各 z は入力 x と補助雑音変数 $\epsilon \sim N(\epsilon; 0, I)$ の決定論的関数として計算される。

$$z = \mu_\phi(x) + \epsilon \cdot \sigma_\phi(x) \quad (6.10)$$

このように再パラメータ化された z のもとで、 ϕ に対して勾配を計算し、 μ_ϕ , σ_ϕ を最適化する。

拡散モデル

拡散モデルは順拡散プロセスと逆拡散プロセスからなる。




図 6.2: 順拡散プロセス (左向き) と逆拡散プロセス (右向き) のグラフィカルモデル. x_0 は自然画像などの真の観測データ, x_T は純粋なガウスノイズ [11].

図 6.2 の通り, 順拡散プロセスは画像 x_0 からタイムステップ t の増える方向に徐々にガウシアンノイズを加え, 最終的に純粋なガウシアンノイズ x_T を得る過程のことである. 一方逆拡散プロセスは純粋なガウシアンノイズ x_T が与えられ, タイムステップ t の減る方向に徐々にノイズを除去していき, 最終的に鮮明な画像 x_0 を得る過程のことである.

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}) \quad (6.11)$$

順拡散プロセスの事後分布 $q(x_{1:T}|x_0)$ は式 (6.11) 式で表せ, 時刻 $t-1$ から t への順拡散事後分布 $q(x_t|x_{t-1})$ は式 (6.12) で表せる. 標準ガウス分布からサンプリングした $\epsilon_t \sim N(0, I)$ を用いるとタイムステップ t の画像 x_t は式 (6.13) として定式化できる. $\beta_t \in (0, 1)$ はタイムステップ t で加えるノイズの大きさを表すパラメータである.

$$q(x_t|x_{t-1}) = N(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) \quad (6.12)$$

$$x_t = \sqrt{1 - \beta_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t \quad (6.13)$$

x_t の画像を得たいときに毎回 t 回計算するのは非効率であるため, x_0 から x_t への拡散を $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, $\epsilon \sim N(0, I)$ を用いて式 (6.14), (6.15) で表される.

$$q(x_t|x_0) = N(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (6.14)$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon \quad (6.15)$$

エンコーダの分布 $q(x_t|x_{t-1})$ は, 各タイムステップにおいて, 定義済みの平均と分散のパラメータを持つガウシアンとして完全にモデル化されるため, もはや ϕ

によってパラメータ化されない。拡散モデルでは、新しいデータをシミュレートできるようにデノイズ $p_\theta(x_{t-1}|x_t)$ を学習することを目的としている。

逆拡散プロセス $p_\theta(x_{0:T})$ は式 (6.16) で表せる。

$$p_\theta(x_{0:T}) := p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t) \quad (6.16)$$

拡散モデルを最適化した後のサンプリング手順は、ガウシアンノイズを $p(x_T)$ からサンプリングし、ノイズ除去遷移 $p_\theta(x_{t-1}|x_t)$ を T ステップ繰り返し、新たな x_0 を生成する。

拡散モデルにおいても ELBO を最大化することで最適化できる。

$$q(x_t|x_{t-1}) = q(x_t|x_{t-1}, x_0) = \frac{q(x_{t-1}|x_t, x_0)q(x_t|x_0)}{q(x_{t-1}|x_0)} \quad (6.17)$$

$$\begin{aligned} ELBO &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t)}{\prod_{t=1}^T q(x_t|x_{t-1})} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1) \prod_{t=2}^T p_\theta(x_{t-1}|x_t)}{q(x_1|x_0) \prod_{t=2}^T q(x_t|x_{t-1})} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1) \prod_{t=2}^T p_\theta(x_{t-1}|x_t)}{q(x_1|x_0) \prod_{t=2}^T q(x_t|x_{t-1}, x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1)}{q(x_1|x_0)} + \log \prod_{t=2}^T \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1}, x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1)}{q(x_1|x_0)} + \log \prod_{t=2}^T \frac{p_\theta(x_{t-1}|x_t)}{\frac{q(x_{t-1}|x_t, x_0)q(x_t|x_0)}{q(x_{t-1}|x_0)}} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1)}{q(x_1|x_0)} + \log \frac{q(x_1|x_0)}{q(x_T|x_0)} + \log \prod_{t=2}^T \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)p_\theta(x_0|x_1)}{q(x_T|x_0)} + \sum_{t=2}^T \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} [\log p_\theta(x_0|x_1)] + \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p(x_T)}{q(x_T|x_0)} \right] + \sum_{t=2}^T \mathbb{E}_{q(x_{1:T}|x_0)} \left[\log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} \right] \\ &= \mathbb{E}_{q(x_1|x_0)} [\log p_\theta(x_0|x_1)] + \mathbb{E}_{q(x_T|x_0)} \left[\log \frac{p(x_T)}{q(x_T|x_0)} \right] + \sum_{t=2}^T \mathbb{E}_{q(x_t, x_{t-1}|x_0)} \left[\log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} \right] \\ &= \mathbb{E}_{q(x_1|x_0)} [\log p_\theta(x_0|x_1)] - D_{KL}(q(x_T|x_0)||p(x_T)) - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)} [D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t))] \end{aligned} \quad (6.18)$$

式 (6.17) はエンコーダの遷移を書き換えベイズ則に従って、変形したものである。これを使用して ELBO は式 (6.18) の 3 項で表される。

- 第一項の $\mathbb{E}_{q(x_1|x_0)} [\log p_\theta(x_0|x_1)]$ は再構成項と解釈され、VAE の ELBO における再構成項と同様、この項はモンテカルロ推定を用いて近似及び最適化できる。
- 第二項の $D_{KL}(q(x_T|x_0)||p(x_T))$ はノイズ化された入力最後の分布が標準ガウス事前分布にどれくらい近いかを示す。学習可能なパラメータはなく、ここでの仮定の元では 0 に等しい。
- 第三項の $\sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)} [D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t))]$ はノイズ除去マッチング項である。求めたいノイズ除去遷移ステップ $p_\theta(x_{t-1}|x_t)$ を、真に正しいノイズ除去遷移ステップの $q(x_{t-1}|x_t, x_0)$ の近似として学習する。 $q(x_{t-1}|x_t, x_0)$ はノイズの多い画像 x_t をどのようにデノイズするかを定義し、最終的に完全にノイズ除去された画像 x_0 がどうあるべきかを知っているため、真に正しいものとして機能させることができる。したがって、この項は KL ダイバージェンスによって測定されているように、2 つのノイズ除去ステップができるだけ一致するときに最小化される。

求めたい $p_\theta(x_{t-1}|x_t)$ は $q(x_{t-1}|x_t, x_0)$ に近似させるようにパラメータ θ を更新していくが、順拡散プロセス $t-1$ から t で用いられる q の分布が逆のステップ t から $t-1$ を進んでいるのに注目してほしい。 $q(x_{t-1}|x_t, x_0)$ は t から $t-1$ の過程でどのようにデノイズするかを定義し、完全にノイズが除去された元画像を知っているため真に正しいデノイズ分布として定義でき、式 (6.17) の変形を用いることでその分布を導出できる。

$$\begin{aligned}
q(x_{t-1}|x_t, x_0) &= \frac{q(x_t|x_{t-1}, x_0)q(x_{t-1}|x_0)}{q(x_t|x_0)} \\
&= \frac{N(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)N(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}}x_0, (1-\bar{\alpha}_{t-1})I)}{N(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)} \\
&= \frac{N(x_t; \sqrt{\alpha_t}x_{t-1}, (1-\alpha_t)I)N(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}}x_0, (1-\bar{\alpha}_{t-1})I)}{N(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)} \\
&\propto \exp \left\{ -\frac{(x_t - \sqrt{\alpha_t}x_{t-1})^2}{2(1-\alpha_t)} - \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0)^2}{2(1-\bar{\alpha}_{t-1})} + \frac{(x_t - \sqrt{\bar{\alpha}_t}x_0)^2}{2(1-\bar{\alpha}_t)} \right\} \\
&= \exp \left\{ -\frac{1}{2} \left[\frac{-2\sqrt{\alpha_t}x_t x_{t-1} + \alpha_t x_{t-1}^2}{1-\alpha_t} + \frac{x_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}}x_{t-1}x_0}{1-\bar{\alpha}_{t-1}} + C(x_t, x_0) \right] \right\} \quad (6.19) \\
&\propto \exp \left\{ -\frac{1}{2} \left[-\frac{2\sqrt{\alpha_t}x_t x_{t-1}}{1-\alpha_t} + \frac{\alpha_t x_{t-1}^2}{1-\alpha_t} + \frac{x_{t-1}^2}{1-\bar{\alpha}_{t-1}} - \frac{2\sqrt{\bar{\alpha}_{t-1}}x_{t-1}x_0}{1-\bar{\alpha}_{t-1}} \right] \right\} \\
&= \exp \left\{ -\frac{1}{2} \left[\frac{1-\bar{\alpha}_t}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})} x_{t-1}^2 - 2 \left(\frac{\sqrt{\alpha_t}x_t}{1-\alpha_t} + \frac{\sqrt{\bar{\alpha}_{t-1}}x_0}{1-\bar{\alpha}_{t-1}} \right) x_{t-1} \right] \right\} \\
&= \exp \left\{ -\frac{1}{2} \left(\frac{1-\bar{\alpha}_t}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})} \right) \left[x_{t-1}^2 - 2 \frac{\left(\frac{\sqrt{\alpha_t}x_t}{1-\alpha_t} + \frac{\sqrt{\bar{\alpha}_{t-1}}x_0}{1-\bar{\alpha}_{t-1}} \right)}{\frac{1-\bar{\alpha}_t}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}} x_{t-1} \right] \right\} \\
&= \exp \left\{ -\frac{1}{2} \left(\frac{1}{\frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}} \right) \left[x_{t-1}^2 - 2 \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)x_0}{1-\bar{\alpha}_t} x_{t-1} \right] \right\} \\
&\propto N \left(x_{t-1}; \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)x_0}{1-\bar{\alpha}_t}, \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} I \right) \quad (6.20)
\end{aligned}$$

式 (6.19) の $C(x_t, x_0)$ は, x_t , x_0 と α の値のみの組み合わせとして計算された x_{t-1} のそれぞれに関する定数項であり, この項は式 (6.20) に暗黙的に返されて平方完成される.

以上から, 各ステップにおいて x_{t-1} は平均 $\mu_q(x_t, x_0)$ と分散 $\sigma_q^2(t)$ で表される正規分布からサンプリングできることが示された.

$$\mu_q(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)x_0}{1-\bar{\alpha}_t}$$

$$\sigma_q^2(t) = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

ここで分散は各タイムステップにおいて定数であることに注目すると, KL ダイバージェンス項の最適化は, 2つの分布の平均のみを考慮すればよい.

$$\mu_\theta(x_t, t) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)\hat{x}_\theta(x_t, t)}{1-\bar{\alpha}_t} \quad (6.21)$$

ノイズの付与された画像 x_t とタイムステップ t から x_0 を予測した値 $\hat{x}_\theta(x_t, t)$ を導入することで, $\mu_\theta(x_t, t)$ を式 (6.21) で定義できる. $\hat{x}_\theta(x_t, t)$ はニューラルネットワーク

ワークによってパラメータ化される．そして最適化問題は次のように単純化される．

$$\begin{aligned}
& \arg \min_{\theta} D_{KL}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t)) \\
&= \arg \min_{\theta} D_{KL}(N(x_{t-1}; \mu_q(x_t, x_0), \sigma_q^2(t)I) || N(x_{t-1}; \mu_{\theta}(x_t, t), \sigma_q^2(t)I)) \\
&= \arg \min_{\theta} \frac{1}{2\sigma_q^2(t)} \left[\left\| \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)\hat{x}_{\theta}(x_t, t)}{1 - \bar{\alpha}_t} - \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)x_0}{1 - \bar{\alpha}_t} \right\|_2^2 \right] \\
&= \arg \min_{\theta} \frac{1}{2\sigma_q^2(t)} \left[\left\| \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t} (\hat{x}_{\theta}(x_t, t) - x_0) \right\|_2^2 \right] \\
&= \arg \min_{\theta} \frac{\bar{\alpha}_{t-1}(1 - \alpha_t)^2}{2\sigma_q^2(t)(1 - \bar{\alpha}_t)^2} \left[\|\hat{x}_{\theta}(x_t, t) - x_0\|_2^2 \right] \tag{6.22}
\end{aligned}$$

拡散モデルを最適化することは任意にノイズが付与された画像から真の画像を予測するニューラルネットワークの学習に帰結する．これを特にイメージパラメタライズ拡散モデルと呼ぶことにする．

DDPM[11] や一般的な拡散モデルの実装では、ノイズの付与された画像からノイズを予測することを目的としている．ノイズを予測することは、ノイズを除去した画像を予測することとほぼ同じであると考えられる．このモデルのことをノイズパラメタライズ拡散モデルと呼ぶことにする．

イメージパラメタライズ拡散モデルでは式 (6.22) で目的関数を得られたが、ノイズパラメタライズ拡散モデルでの目的関数を考える．

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_0}{\sqrt{\bar{\alpha}_t}} \tag{6.23}$$

式 (6.15) を変形することで式 (6.23) が得られる．これを用いて平均 $\mu_q(x_t, x_0)$ に代入することでノイズパラメタライズ拡散モデルの平均 $\mu_q(x_t, \epsilon_0)$ は次のように導出できる．

$$\begin{aligned}
\mu_q(x_t, \epsilon_0) &= \mu_q(x_t, x_0) \\
&= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)x_0}{1 - \bar{\alpha}_t} \\
&= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)\frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_0}{\sqrt{\bar{\alpha}_t}}}{1 - \bar{\alpha}_t} \\
&= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})x_t + (1 - \alpha_t)\frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_0}{\sqrt{\bar{\alpha}_t}}}{1 - \bar{\alpha}_t} \\
&= \left(\frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} + \frac{1 - \alpha_t}{(1 - \bar{\alpha}_t)\sqrt{\bar{\alpha}_t}} \right) x_t - \frac{(1 - \alpha_t)\sqrt{1 - \bar{\alpha}_t}}{(1 - \bar{\alpha}_t)\sqrt{\bar{\alpha}_t}} \epsilon_0 \\
&= \frac{1 - \bar{\alpha}_t}{(1 - \bar{\alpha}_t)\sqrt{\bar{\alpha}_t}} x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}\sqrt{\bar{\alpha}_t}} \epsilon_0 \\
&= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_0 \right) \tag{6.24}
\end{aligned}$$

ノイズの付与された画像 x_t とタイムステップ t からノイズを予測するニューラルネットワークの出力 $\hat{\epsilon}_\theta(x_t, t)$ を導入することで, $\mu_\theta(x_t, t)$ を式 (6.25) で定義できる.

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_\theta(x_t, t) \right) \tag{6.25}$$

したがって, ノイズパラメタライズ拡散モデルにおける最適化問題は式 (6.26) のようになる.

$$\begin{aligned}
&\arg \min_{\theta} D_{KL}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t)) \\
&= \arg \min_{\theta} D_{KL}(N(x_{t-1}; \mu_q(x_t, \epsilon_0), \sigma_q^2(t)I) || N(x_{t-1}; \mu_\theta(x_t, t), \sigma_q^2(t)I)) \\
&= \arg \min_{\theta} \frac{1}{2\sigma_q^2(t)} \left[\left\| \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_\theta(x_t, t) \right) - \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_0 \right) \right\|_2^2 \right] \\
&= \arg \min_{\theta} \frac{1}{2\sigma_q^2(t)} \left[\left\| \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}\sqrt{\alpha_t}} \epsilon_0 - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}\sqrt{\alpha_t}} \hat{\epsilon}_\theta(x_t, t) \right\|_2^2 \right] \\
&= \arg \min_{\theta} \frac{(1 - \alpha_t)^2}{2\sigma_q^2(t)(1 - \bar{\alpha}_t)\alpha_t} \left[\|\epsilon_0 - \hat{\epsilon}_\theta(x_t, t)\|_2^2 \right] \tag{6.26}
\end{aligned}$$

$\hat{\epsilon}_\theta(x_t, t)$ は x_0 から x_t を決定するソースノイズ $\epsilon_0 \sim N(\epsilon; 0, I)$ を予測するように学習するニューラルネットワークである. したがって, 元画像 x_0 を予測して拡散モデルを学習するイメージパラメタライズ拡散モデルとノイズを予測するように学習するノイズパラメタライズ拡散モデルは同等であることが以上の式変形から示される. 経験的には, ノイズを予測した方が性能がいいという研究もある. [30, 31]