

修 士 論 文

フローマッチングを用いた共同学習による センサ基盤モデルに関する研究

2025 年度

九州工業大学大学院情報工学府
情報創成工学専攻

246E0009

浮田 嵩祐

指導教員：大北 剛 准教授

論文概要

九州工業大学大学院情報工学府 情報創成工学専攻 知能情報工学専門分野

学生番号	246E0009	氏名	浮田 嵩祐
論文題目	フローマッチングを用いた共同学習による センサ基盤モデルに関する研究		

1 はじめに

近年、拡散モデルはその生成過程で高度な表現を獲得できるため、新たな自己教師あり学習 (SSL) として期待されている。しかし、既存手法は、「生成品質と認識性能のトレードオフ」および「膨大な計算コスト」という二つの課題を抱えている。生成に特化すると認識に不要なノイズまで学習してしまい、逆に認識に特化すると生成能力が損なわれる。本研究では、これらの課題を解決するため、フローマッチングに基づく新しい基盤モデル SenFlow を提案する。本手法は、生成と認識のコンポーネントを明示的に分離し、これらを共同で学習する。ウェアラブルセンサデータを用いた実験では、SenFlow は拡散モデル比で学習時間を 50.4%削減し、推論速度を最大 51.0 倍高速化した。さらに、行動認識タスクでは全 5 データセットで最先端手法 (SSL-Wearables) を凌駕する性能を達成し、高い生成品質と認識性能の両立を実証した [1]。

2 提案手法




図 1: SenFlow の学習アーキテクチャ。

フローマッチング [3] に基づいた SenFlow は、Representation Encoder f_ϕ と Velocity Field Network v_θ の 2 つのコンポーネントを分離し、これらを同時に訓練するアーキテクチャを採用する (図 1)。表現エンコーダの出力を生成の条件として用いつつ、生成ロスの勾配をエンコーダにも逆伝播させる。これに

より、エンコーダは「生成を助けるための本質的なデータ構造」を抽出するように動的に最適化される。さらに、訓練中に一定確率 (50%) で条件表現をマスクする新しい学習戦略 (DGS) を導入する。これにより、エンコーダへの過度な依存を防ぐ正則化効果と、条件なし生成能力の獲得を同時に実現する。

3 実験結果

ウェアラブルセンサデータを用いて、本手法の有効性を検証する。人間行動認識タスクでは、表 1 に示す通り、SenFlow は最先端の SSL 手法 (SSL-Wearables [2]) および拡散モデルベースの比較手法 (SenDiff) に対し、**を達成した。特に REALWORLD ではベースライン比+12.9%の向上を示した。

表 1: 行動認識タスクにおける F1-score の比較

Method	adl.	oppo.	pamap.	real.	wis.
SSL-Wearables [2]	.8290	.5950	.7890	.7920	.8100
SenDiff (Ours)	.9118	.7782	.8877	.9197	.8832
SenFlow (Ours)	.9286	.7925	.8877	.9211	.8910

計算コストに関して、SenFlow は SenDiff と比較して、学習時間を 50.4%削減し、生成性能を維持しながら (FID 5.014)、推論速度を最大 51.0 倍高速化した。また、Text-to-Signal 生成タスクにおいて、獲得した表現と LLM を組み合わせることで、テキスト記述から、個人の属性や動作のニュアンスを反映した高品質な時系列信号を生成できることを確認した。

4 結論

本研究では、フローマッチングを用いたセンサ基盤モデル SenFlow を提案した。本手法は、生成と認識のトレードオフを解消するとともに、計算効率と品質を向上させることで本基盤モデルの有効性を示した。これは、リソース制約のあるエッジデバイスにおける高効率な AI 応用に道を拓くものである。今後の展開として、多様なモダリティへの適用や、計算効率化の詳細なメカニズム解明を考えている。

参考文献

- [1] K. Ukita and T. Okita, "High-Performance Self-Supervised Representation Learning...", *AISTATS 2026*, 2026.
- [2] Y. Yuan et al., "Self-supervised learning for human activity recognition...", *IMWUT 2024*, 2024.
- [3] Lipman et al., "Flow Matching for Generative Modeling," *ICLR 2023*, 2023.

目次

第1章	はじめに	2
1.1	研究背景	2
1.2	課題と目的	3
1.3	本研究のアプローチ	4
1.4	本論文の貢献	4
1.5	本論文の構成	5
第2章	関連研究	6
2.1	自己教師あり学習	6
2.2	拡散モデルによる表現学習	7
2.3	高効率な生成モデル	8
2.4	大規模センサ基盤モデル	8
第3章	予備知識	10
3.1	潜在拡散モデル	10
3.2	フローマッチング	10
第4章	提案手法	13
4.1	事前学習	14
4.2	下流タスク	17
第5章	実験	20
5.1	データセット	20
5.2	人間行動認識結果	21
5.3	Text-to-Signal 生成結果	23
5.4	計算効率の低減	25
第6章	結論	27
	研究業績	29

Abstract

Diffusion models can learn rich representations during data generation, showing potential for Self-Supervised Learning (SSL), but they face a trade-off between generative quality and discriminative performance. Their iterative sampling also incurs substantial computational and energy costs, hindering industrial and edge AI applications. To address these issues, we propose the Flow Matching-based Sensor Foundation Model (SenFlow), which jointly trains a representation encoder and a conditional flow matching generator. This decoupled design achieves both high-fidelity generation and effective recognition. By using flow matching to learn a simpler velocity field, SenFlow accelerates and stabilizes training, improving its efficiency for representation learning. Experiments on wearable sensor data show SenFlow reduces training time by 50.4% compared to a diffusion-based approach. On downstream tasks, SenFlow surpassed the state-of-the-art SSL method (SSL-Wearables) on all five datasets while achieving up to a 51.0x inference speedup and maintaining high generative quality.

第1章 はじめに

1.1 研究背景

近年の機械学習研究，とりわけ基盤モデルの進展において，自己教師あり学習（SSL）は標準的な学習パラダイムの一つとして定着している．大規模言語モデルの爆発的な成功は，ラベルなしデータから汎用的な表現を学習する SSL の有効性を決定づけた．BERT [8] や GPT シリーズ [27] に見られるように，大量のテキストデータから “Masked-token” や “Next-token prediction” といったプレテキストタスクを通じて学習されたモデルは，翻訳，要約，対話といった下流タスクにおいて驚異的な適応能力を示している．このパラダイムシフトは，高品質なアノテーションを必要とすることなく，データそのものが持つ潜在的な構造をモデルに理解させるための強力なアプローチとなっている．

一方，生成モデルの分野において，拡散モデル [16] は高品質なデータ生成を可能にする技術として急速に発展している．拡散モデルは，データにノイズを徐々に加える拡散過程と，その逆変換を学習する生成過程を通じて，従来の VAE [20] や GAN [12] を凌駕する高品質なデータ生成能力を示している．当初は画像生成の分野で驚異的な品質を達成したことで注目を集めたが，その影響はもはや単一のドメインに留まらない．現在では動画生成 [46]，時系列予測 [24]，高品質な音声合成 [34]，そしてその推論速度から，近年急速に注目を集める拡散言語モデルにおけるテキスト生成 [25, 39]，さらには創薬のための 3D 分子構造設計 [18]，ロボティクスのための行動計画 [33] など，科学から工学に至るまで極めて広範な領域で応用され，ブレークスルーを生み出し続けている．

この拡散モデルの爆発的な成功の裏で，表現学習の文脈における極めて重要な発見がなされた．それは，高品質なデータを生成する過程で，モデルが意図せずしてデータの構造を深く理解し，高品質な識別的特徴を獲得しているという事実である [7, 42]．この事実は，拡散モデルが単なる生成器としてだけでなく，強力な SSL フレームワークとしての潜在能力を持つことを強く示唆している．しかしながら，拡散モデルを表現学習へと応用する既存の研究は，依然として「生成品質と認識性能のトレードオフ」という根源的なジレンマを抱えている．

1.2 課題と目的

第一の課題は、生成能力と識別能力の両立の難しさである。既存のアプローチの一つは、事前に学習された生成モデルを再利用するもの（例：DDAE [42]）である。これらは元データの忠実な再構成に特化しているため、その内部表現は必ずしも下流の認識タスクに最適化されておらず、ノイズやタスクに無関係な詳細情報まで過剰に符号化してしまう傾向がある [43]。もう一つのアプローチは、表現学習に特化してモデルアーキテクチャを再設計するもの（例：I-DAE [7], SODA [19]）である。これらは識別性能を追求するためにボトルネック構造などを導入するが、その代償として、拡散モデルの最大の強みである強力な生成能力が損なわれることが多い。すなわち、元データの微細なディテールまで忠実に再現しようとする生成の目的と、タスクに無関係な変動に対して不変であるべき認識の目的は、本質的に対立する側面を持つ [7, 9]。

第二の課題は、拡散モデル特有の膨大な計算コストである。拡散モデルは、ノイズからデータを生成するために、数十から数千ステップに及ぶ反復的なノイズ除去プロセスを必要とする。これは、学習および推論の両面において多大な計算資源と時間を消費することを意味する。特に、ウェアラブルデバイスやエッジデバイスのような、計算能力やバッテリー容量に制約のある環境において、従来の拡散モデルベースの表現学習を適用することは実用上極めて困難である。産業応用やリアルタイム処理を見据えた場合、高性能でありながら軽量かつ高速なモデルの構築が不可欠である。

以上の背景と課題認識に基づき、本研究では以下の2つのリサーチクエスチョン（RQ）を設定し、その解明に取り組む。

RQ1: 生成品質と認識性能の両立は可能か？

拡散モデルを用いた表現学習において、生成能力の追求と識別的な特徴獲得は本質的にトレードオフの関係にあるとされる。適切なアーキテクチャ設計と学習戦略により、このトレードオフを解消し、両者を高水準で両立させることは可能か？

RQ2: 拡散モデルの計算ボトルネックを克服できるか？

従来の拡散モデルは学習と推論に膨大な計算資源と時間を必要とする。生成品質と認識性能を維持しつつ、この計算コストを劇的に削減し、より高速かつエネルギー効率に優れた基盤モデルを構築することは可能か？

これらの問いに答えるため、本論文では以下の新しいアプローチを提案する。

1.3 本研究のアプローチ

上述した「生成と認識のトレードオフ」と「計算コスト」という二重の課題を同時に克服するため、本論文では、フローマッチングに基づく新しい基盤モデルである SenFlow (Flow Matching-based Sensor Foundation Model) を提案する。我々のアプローチの核心は、汎用的な「表現エンコーダ」と高品質な「生成ネットワーク」という二つのコンポーネントを明示的に分離し、これらを同時に訓練するアーキテクチャを採用することにある。この設計により、表現エンコーダは入力信号からロバストで識別的な特徴を抽出することに専念し、生成ネットワークはその抽出された表現を条件として、元の高品質な信号を復元することに専念できる。さらに、この分離アーキテクチャを効率的に学習させるために、拡散モデルではなく、フローマッチング [22] の枠組みを導入する。フローマッチングは、確率微分方程式 (SDE) に基づく拡散モデルとは異なり、決定論的な常微分方程式 (ODE) の速度場を直接学習する手法であり、拡散モデルに匹敵する強力な生成能力を維持しつつ、よりシンプルで高速な生成を可能にする次世代の生成パラダイムである。SenFlow は、計算効率に優れたフローマッチングの枠組みの中に、前述の認識と生成のために分離されたアーキテクチャを統合することで、表現エンコーダは識別的特徴の学習に、そして速度場予測ネットワークは高品質な生成に、それぞれ特化して最適化される。

我々の提案する SenFlow は、このアーキテクチャ上の分離とフローマッチングの計算効率を両立させることにより、生成能力と認識能力を互いに犠牲にすることなく、かつ計算コストの大幅な軽量化を達成し、ウェアラブルセンサデータにおけるより汎用的で強力な基盤モデルの構築を目指すものである。

1.4 本論文の貢献

本論文の主な貢献は以下のとおりである。

- フローマッチングの生成プロセスを表現学習に直接利用する、新しい基盤モデル SenFlow を提案する。
- フローマッチングの目的関数を用いて、表現エンコーダと速度場予測ネットワークの2つを同時に訓練する効率的な共同学習手法を提案する。
- 複数のウェアラブルセンサデータセットを用いた実験により、提案手法の有効性を検証する。人間行動認識タスクにおいて、SenFlow は最先端の SSL

ベースラインである SSL-Wearables を，全 5 つのデータセットにおいて一貫して上回る性能を発揮することを示す．

- Text-to-Signal 生成タスクを通じ，学習した表現が識別情報だけでなく，テキスト記述に対応する意味的な構造や微細な信号パターンまでも捉え得ることを定性的に実証する．
- 計算効率の観点において，従来の拡散モデルベースのアプローチと比較して，学習時間を約 50% 短縮し，推論速度を最大 51 倍高速化できることを示す．これは，オンデバイス AI やエッジコンピューティングにおける持続可能な基盤モデルの実現に向けた重要な貢献である．

1.5 本論文の構成

本論文の構成は以下の通りである．第 2 章では，自己教師あり学習および拡散モデルを用いた表現学習に関する関連研究について概説する．第 3 章では，本研究の基礎となる潜在拡散モデルおよびフローマッチングの理論的背景について述べる．第 4 章では，提案手法である SenFlow のアーキテクチャ，学習目的関数，および動的な条件付け機構について詳細に説明する．第 5 章では，ウェアラブルセンサデータセットを用いた定量的な行動認識実験，および Text-to-Signal 生成による評価結果を示し，提案手法の優位性を議論する．最後に，第 6 章で本論文の結論を述べるとともに，今後の展望について言及する．

第2章 関連研究

本章では、本研究の提案手法である SenFlow の着想に至る背景と、関連する研究領域の動向について詳細に述べる．まず，2.1 節では，自己教師あり学習の代表的な手法と，画像および時系列データにおける発展について概説する．次に，2.2 節では，拡散モデルを用いた表現学習の現状と，生成品質と識別性能のトレードオフに関する課題，および最新の生成ガイド手法との比較を行う．続いて，2.3 節では，本研究の中核技術であるフローマッチングの理論と利点について述べる．最後に，2.4 節では，近年急速に立ち上がりつつある「時系列・センサ基盤モデル」という文脈における本研究の位置付けを明らかにする．

2.1 自己教師あり学習

自己教師あり学習（SSL）は，人手によるアノテーションを必要とせず，データ自体から擬似的な教師信号を生成することで，汎用的かつロバストな特徴表現を学習する枠組みである．現代の SSL は，主にマスキングと対照学習，そしてそれらを統合するアプローチによって発展してきた．

マスキング

マスキングは，入力シーケンスの一部を意図的にマスクし，周囲の文脈情報からマスクされた部分を復元・予測するようにモデルを訓練する手法である．このアプローチは，自然言語処理における BERT [8] の登場によって革命をもたらし，文脈を双方向から考慮した深い意味理解を可能にした．その後，この概念はコンピュータビジョンにおけるマスクオートエンコーダ（MAE）[14] へと拡張され，画像生成や認識タスクにおいても絶大な成功を収めている．この手法の本質は，局所的な欠損情報を復元するという困難なタスクを解くことを通じて，モデルにデータ全体の大域的な文脈理解と，意味的な表現の獲得を強制する点にある．

対照学習

対照学習は、データ間の類似性を学習の手がかりとする。SimCLR [6]やMoCo [15]などの代表的手法では、同一データから生成された拡張データ同士を近づけ、異なるデータ同士を遠ざけるように学習する。また、DINO [4]は、教師なしでの自己蒸留の枠組みを導入し、明示的な負例を用いずに高品質な表現を獲得することに成功した。これらの手法は、ダウンストリームタスクにおいて高い線形分離性を発揮するが、データの適切な「拡張」の設計に強く依存しており、ドメイン知識が必要となる点が課題である。

統合アプローチ

近年では、iBOT [47]やDINOv2/v3 [28, 35]のように、マスク再構成と対照学習的な識別目的を同時に最適化する手法が画像分野で成功を収めている。これらは、局所的なテクスチャの復元と大域的な意味理解を両立させる優れたアプローチである。しかしながら、これらの手法を時系列センサデータに直接適用することは困難である。画像データが高い空間的冗長性を持ち、周囲のパッチから欠損を推論しやすいのに対し、加速度計などのセンサデータは変動が激しく、かつ意味的な密度が低いため、単純なマスキングと再構成だけでは自明な補間を学習してしまい、深い意味表現の獲得につながらない [10]。本研究では、単純な欠損復元ではなく、ノイズ分布からデータ分布への複雑な変換過程全体を学習させることで、時系列データの構造的理解を促進する。

2.2 拡散モデルによる表現学習

生成モデル、特に拡散モデルの発展は、SSLに新たな可能性をもたらした。

生成と認識のジレンマ

拡散モデルの中間層が、生成過程で意図せずして高品質な識別的特徴を獲得していることが発見されて以来 [42]、これをSSLに応用する試みがなされてきた。DDAE [42]やDiffusion Classifier [21]は、事前学習済みの生成モデルを特徴抽出器として再利用する。しかし、これらは「元データの忠実な再構成」に特化しているため、ノイズや背景情報などのタスクに無関係な詳細まで過剰に符号化してしまう傾向がある [43]。一方で、I-DAE [7]やSODA [19]のように表現学習に特化

してモデルを再設計すると、今度は生成能力が犠牲になるというトレードオフが存在する。

表現ガイダンス手法との比較

生成と認識の連携に関する最新のアプローチとして、REPA [44] などが提案されている。REPA は訓練済みの強力な SSL 表現（DINOv2 等）を用いて、拡散モデルの生成プロセスに条件付けてガイドすることで、生成品質と収束速度を向上させる手法である。これに対し、本研究の SenFlow は、識別器と生成器をゼロから同時に学習させる点に決定的な違いがある。既存の強力な表現に頼るのではなく、生成タスクそのものを目的として、高品質な表現と生成モデルを同時に取得できる点が本研究の独自性である。

2.3 高効率な生成モデル

拡散モデルの実用上の最大の課題は、反復的なサンプリングに伴う計算コストである。これを解決するため、近年フローマッチング [22] が注目されている。従来の拡散モデルが確率微分方程式（SDE）に基づく複雑なノイズ除去過程を経るのに対し、フローマッチングは、確率分布間の移動を記述する決定論的な常微分方程式（ODE）の速度場を直接学習する。最適輸送の概念を取り入れることで、始点と終点を結ぶ直線経路を学習することが可能となり、拡散モデルに比べて極めて少ないステップ数で高品質な生成が可能となる [23]。本研究では、この計算効率の高さを活かし、学習と推論のコストを大幅に削減することで、エッジデバイスやウェアラブルデバイスへの将来的な実装を見据えた基盤モデルを構築する。

2.4 大規模センサ基盤モデル

最後に、本研究の「基盤モデル」としての位置付けについて述べる。一般に基盤モデルとは、GPT のような LLM や、Stable Diffusion のような画像生成モデルを指すことが多い。しかし近年、時系列データや物理センサデータの領域においても、大規模データセットで事前学習を行い、多様なダウンストリームタスク（分類、予測、補完、生成など）に適応可能な「時系列基盤モデル」の構築が試みられている。代表的な例として、Chronos [1] や MOMENT [13] が挙げられる。

本研究の SenFlow は、これらの流れを汲むものであり、特にウェアラブルセンサデータにおける「認識」と「生成」の両方を高水準でこなすことができる「セン

「サ基盤モデル」として位置付けられる。単一のタスクに特化するのではなく、学習された表現がテキスト条件付き生成や行動認識といった全く異なるタスクに転用可能であることを示すことで、センサデータ領域における基盤モデルの可能性を実証する。

第3章 予備知識

本章では、本研究の提案手法を構成する核心技術である「潜在拡散モデル」と「フローマッチング」について、その理論的背景と基本原理を概説する。

3.1 潜在拡散モデル

拡散モデルは、データに徐々にノイズを加えて完全なランダムノイズにする「拡散過程」と、その逆変換を学習してノイズからデータを復元する「生成過程」から構成される。DDPM [16] やスコアベースモデル [36] といった初期の拡散モデルは、ピクセル空間で直接この過程を学習していたため、高解像度データや長時間の時系列データを扱う際に膨大な計算コストを要するという課題があった。

これに対し、潜在拡散モデル (LDM) [32] は、VAE などの知覚圧縮モデルを用いてデータを低次元の潜在空間へ写像し、その圧縮された潜在表現上で拡散モデルを構築する手法である。これにより、知覚的な品質を維持しつつ、学習および推論の計算効率を劇的に向上させることに成功している。

さらに、拡散モデルのバックボーンアーキテクチャに関しても進化が見られる。従来主流であった CNN ベースの U-Net に代わり、Transformer を採用した Diffusion Transformer (DiT) [29] が提案されている。DiT は、Self-Attention 機構によりデータ内の大域的な依存関係を効果的に捉えることが可能であり、モデルサイズや学習データ量の増加に伴って性能がスケラブルに向上するという特性を持つ。本研究では、時系列データの長期的な文脈を捉える能力と高いスケラビリティを重視し、この DiT をベースアーキテクチャとして採用する。

3.2 フローマッチング

フローマッチング [22] は、連続正規化フロー (CNF) [5] に基づく新しい生成モデルのパラダイムである。拡散モデルが確率微分方程式 (SDE) に基づく確率的な経路を辿るのに対し、フローマッチングは、単純な事前分布 p_0 から複雑なデー

タ分布 p_1 へと確率質量を輸送する、決定論的な常微分方程式 (ODE) の速度場を直接学習することを目的とする。

条件付きフローマッチング

分布全体の周辺速度場を直接学習することは計算上困難であるため、条件付きフローマッチング [22] は、個々のサンプルペア（ソース x_0 とターゲット x_1 ）に条件付けられた単純な速度場をターゲットとすることで、この問題を解決した。具体的には、まずサンプリングが容易な事前分布 p_0 からソースサンプル $x_0 \in \mathbb{R}^d$ を、訓練データ分布 p_1 からターゲットサンプル $x_1 \in \mathbb{R}^d$ を取得する。次に、時刻 $t \in [0, 1]$ を用いて、これら 2 点を結ぶ確率パス上の点 x_t を構成する。本研究では、最適輸送の観点から最も効率的とされる線形補間を採用している（式 (3.1)）。

$$x_t = (1 - t)x_0 + tx_1 \quad (3.1)$$

このパスに対応する条件付きターゲット速度場 $u_t(x|x_0, x_1)$ は、時間微分により式 (3.2) のように一意かつ単純に導出される。

$$\begin{aligned} u_t(x_t|x_0, x_1) &= \frac{d}{dt}x_t \\ &= x_1 - x_0 \end{aligned} \quad (3.2)$$

すなわち、ターゲット速度はソースからターゲットへ向かう一定のベクトルとなる。これにより、モデルは真っ直ぐで曲率のない安定した軌道を学習することになる。

訓練目的

条件付きフローマッチング (CFM) の学習目的は、ニューラルネットワークによりパラメータ化された速度場モデル $v_\theta(x, t)$ が、上記のターゲット速度 u_t を予測できるようにすることである。損失関数 $\mathcal{L}_{CFM}$ は、パス上の任意の点における予測値とターゲットとの二乗誤差として定義される（式 (3.3)）。

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{t \sim [0, 1], x_0 \sim p_0, x_1 \sim p_1} [\| v_\theta(x_t, t) - (x_1 - x_0) \|^2] \quad (3.3)$$

この目的関数は、拡散モデルにおけるスコアマッチング目的関数と比較して、ターゲットが明確で変動が少ないため、学習が安定しやすく収束が早いという利点がある。

推論プロセス

推論時には、学習された速度場モデル v_θ を用いて、事前分布からのサンプル $x_0 \sim p_0$ を初期値とする常微分方程式（ODE）を数值的に解くことで、データ x_1 を生成する（式 (3.4)）。

$$dx = v_\theta(x, t)dt \quad (3.4)$$

学習されたフローは線形に近い単純な軌道を描くため、オイラー法や RK45 などの ODE ソルバを用いて、極めて少ないステップ数（10～20 ステップ）で高品質なサンプルを生成することが可能となる。これが、拡散モデルと比較した際の推論速度の優位性の根拠である。

第4章 提案手法

本節では、フローマッチングを用いた新たなセンサ基盤モデルである SenFlow について詳細に説明する。本手法は、BERT [8] や DINO [4] といった従来の自己教師あり学習と同様に、大規模なラベルなしデータセットを用いた「事前学習」と、少量のラベル付きデータセットを用いた「下流タスク」の二段階のプロセスを採用する。

本研究の目的は、この自己教師あり学習のフレームワークを、生成モデルであるフローマッチングを用いて構築することにある。一般的な条件付き生成モデル（例：Text-to-Image）は、テキストと画像のペアデータを用いて、テキスト条件付きのデータ生成プロセスを学習する。しかし、センサデータの領域において、大規模なアノテーション付きデータセットを用意することはコストの観点から極めて困難である。そこで本研究では、アノテーションを一切必要としない「表現条件付きのデータ生成プロセス」をゼロからフルスクラッチで学習することで事前学習済みモデルを構築するアプローチをとる。これにより、ラベルなしデータのみから高品質な表現獲得とデータ生成の両立を目指す。




図 4.1 事前学習時における SenFlow の概要図．（左）Representation Encoder f_ϕ と（右）Velocity Field Network v_θ で構成される． f_ϕ は入力 x_1 から表現 r を抽出し、条件として v_θ に供給する． v_θ は確率パス上の点 x_t と条件（表現 r 、時刻 t 、テキスト y ）を受け取り、ターゲット速度場 u_t を予測するように共同学習される．DGS モジュールは、学習中に r をランダムにマスクすることで、表現への過度な依存を防ぎ、ロバスト性を向上させる．

4.1 事前学習

SenFlow の事前学習におけるアーキテクチャを図 4.1 に示す．モデルは主に、入力データから特徴を抽出する「Representation Encoder $f_\phi(\cdot)$ 」と、特徴を条件としてデータを生成する「Velocity Field Network $v_\theta(\cdot)$ 」の 2 つのコンポーネントから構成される．

共同学習の目的

まず、入力データ x_1 を受け取り、表現ベクトル $r \in \mathbb{R}^d$ を出力する表現エンコーダ f_ϕ を式 (4.1) として定義する.

$$r = f_\phi(x_1) \quad (4.1)$$

この表現 r は、生成ネットワーク v_θ に対する条件の一つとして入力される. ここで、テキストなどの一般的な条件 c に基づく条件付き生成プロセスを訓練するフローマッチングの損失関数は、式 (4.2) のように記述される. これは、事前分布 p_0 から、条件 c が与えられた時のターゲット分布 $p_1(x_1|c)$ へのフローを学習することを意味する.

$$\mathcal{L}_{CFM, cond}(\theta) = \mathbb{E}_{t, x_0, (x_1, c)} [\| v_\theta(x_t, t, c) - u_t(x_t|x_1, c) \|^2] \quad (4.2)$$

SenFlow では、表現エンコーダから得られる表現 $r = f_\phi(x_1)$ を条件 c として用いる. 重要な点は、この条件 r が固定された値ではなく、表現エンコーダのパラメータ ϕ に依存して動的に変化する点である.

したがって、SenFlow の損失関数 $\mathcal{L}_{SenFlow}$ は、生成ネットワークのパラメータ θ と表現エンコーダのパラメータ ϕ の双方に関して最適化される (式 (4.3)).

$$\begin{aligned} \mathcal{L}_{SenFlow}(\theta, \phi) &= \mathbb{E}_{t, x_0, x_1} [\| v_\theta(x_t, t, r) - u_t(x_t|x_1, r) \|^2] \\ &= \mathbb{E}_{t, x_0, x_1} [\| v_\theta(x_t, t, f_\phi(x_1)) - u_t(x_t|x_1, f_\phi(x_1)) \|^2] \end{aligned} \quad (4.3)$$

既存の拡散モデルを用いた表現学習手法 [44, 32, 2] の多くは、訓練済みのパラメータが固定されたエンコーダを使用しており、条件となる表現は静的である. これに対し、本手法は生成プロセスの訓練と同時に表現エンコーダも訓練される. すなわち、フローマッチングの生成タスクという訓練目的による、誤差逆伝播を通じて、表現エンコーダは「生成タスクを補助するデータの本質を捉えた表現」を抽出するように学習され、結果として高度な認識能力を獲得することが期待される.

さらに、式 (4.3) は式 (4.4) のように書き換えることができる.

$$\mathcal{L}_{SenFlow}(\theta, \phi) = \mathbb{E}_{t, x_0, x_1} [\| v_\theta^\phi(x_t, t) - u_t^\phi(x_t|x_1) \|^2] \quad (4.4)$$

式 (4.4) は、表現エンコーダ f_ϕ のパラメータ ϕ が、単に静的な条件を与えるのではなく、ターゲットとなる速度場 u_t そのものを動的にパラメータ化していることを示唆している. つまり、本フレームワークは、固定された複雑な生成問題を解くのではなく、表現エンコーダが「生成問題を単純化するようなパス (速度場 u_t^ϕ)」を能動的にデザインし、その単純化された問題を生成器が解くという、問題設定の最適化という表現学習と、生成学習を同時に行うプロセスとして解釈できる.

モデルアーキテクチャ

本研究では、1次元の時系列センサデータを扱うため、画像生成で標準的な DiT [29] および ViT [11] を以下のように改良して用いる。

Velocity Field Network (v_θ)

DiT [29] アーキテクチャを基盤とする。オリジナルの DiT は 2 次元画像をパッチ分割して処理するが、本研究では 1 次元センサデータに対応するため、入力層を 1 次元畳み込み層に変更した。これにより、連続的な時系列信号を Transformer ブロックが処理可能なトークン列へ変換する。

Representation Encoder (f_ϕ)

ViT [11] アーキテクチャを採用し、同様に入力層を 1 次元畳み込み層へ変更している。入力された時系列データ全体から、[CLS] トークンに対応する単一の特徴ベクトルを抽出し、これを表現ベクトル r とする。

条件付けメカニズム

生成プロセスを制御するため、速度場ネットワークには複数の条件が与えられる。基本となる条件は: (1) 表現ベクトル r と、(2) タイムステップ t である。 t は三角関数ベースの埋め込み層によりベクトル化される。これら 2 つの条件ベクトルは、要素ごとに結合された後、各 DiT ブロックに *adaLN-Zero*¹機構を介して組み込まれる。さらに、下流タスクでの様々なタスクを考慮し、このモジュールはパディング項を追加することで、テキストプロンプトなど任意の複数の条件を追加できるように設計してある。

Dynamic Guidance Switching

さらに、モデルの汎用性と表現のロバスト性を高めるため、「Dynamic Guidance Switching (DGS)」と呼ぶ学習戦略を導入する。これは、訓練ステップごとに一定確率（本研究では 50%）で、条件である表現ベクトル r をゼロベクトル（Null Condition）に置換するものである。DGS の導入には二つの目的がある。第一に、表現なしでの生成（無条件生成）能力をモデルに学習させることである。これにより、Classifier-Free Guidance [17] のような生成制御が可能となる。第二に、表現エンコーダに対する正則化である。常に完全な表現が与えられると、生成器は表現に過度に依存し、デコーダとしての役割に特化してしまう恐れがある。DGS により表現が時折遮断されることで、生成器は自律的な生成能力を維持する必要性が生じ、同時にエンコーダは「与えられた時に最大限生成を助ける本質的な情報」を圧縮して詰め込むように学習が進む。

¹DiT で採用されている条件組み込みメカニズム

実際にこの有効性を検証するため、DGSにおけるマスキング確率の感度分析を行った。正則化効果についてより深い洞察を得るため、広範囲（0%, 25%, 50%, 75%）での比較検証を実施した。5回の異なるシード値での実験による F1-score (mean±std) を評価指標として採用した。表 4.1 に結果を示す。結果として、50% 付近で最も高い性能が得られており、適度なマスキングがエンコーダに本質的な特徴抽出を促すという仮説を強く裏付けている。

表 4.1 マスキング戦略の効果：マスク確率 0%, 25%, 75%, 50%でのファインチューニング精度の比較。50%の設定（DGS）は全てのデータセットにおいて一貫して高い精度をもたらしており、適切なランダムマスキングがよりロバストな表現の学習に寄与することを示している。

Mask prob.	ADL	Opportunity	PAMAP2	REALWORLD
0%	.861±.012	.765±.088	.872±.042	.911±.030
25%	.894±.091	.776±.083	.873±.083	.918±.042
50%	.929±.073	.790±.072	.883±.023	.919±.092
75%	.895±.019	.775±.013	.863±.108	.907±.031

4.2 下流タスク

事前学習されたモデルの有用性を検証するため、以下の2つのタスクを実施する。

Human Activity Recognition (HAR) Task

獲得された表現の「識別能力」を評価する。事前学習済みの表現エンコーダを用い、(1) エンコーダを凍結して線形分類器のみを学習する「転移学習」、および (2) 訓練済み表現エンコーダを初期値として全層を更新する「ファインチューニング」の2設定で評価を行う。

Text-to-Signal Task

獲得された表現が、単なるクラス分類のための情報だけでなく、データの生成的構造や意味的な詳細な情報を捉えているかを検証するため、テキスト記述からの信号生成タスクを行う。図 4.2 に概要を示す。事前学習済みの SenFlow は、まだテキスト条件を受け取れないため、下流タスクとしてテキスト条件を受け取るよ




図 4.2 Text-to-Signal の概念図： 1.Tuning では，速度場ネットワーク v_θ が，固定されたコンポーネントと共に，表現 r とテキスト埋め込み y の両方を条件としてファインチューニングされる． 2.Inference では，モデルはテキスト y のみを条件として，ODE ソルバを介してノイズ x_0 から信号 x_1' を生成する．

うに速度場ネットワーク v_θ のチューニングを行う．ここで重要なのがチューニング時の条件付けである．我々は，テキスト埋め込み y に加え，事前学習済みエンコーダから抽出した表現 r を補助的な条件として与えてチューニングを行う（Text + Rep）．拡散モデルの先行研究 [44, 2] において，凍結された表現を条件に加えることで生成品質が向上することが知られている．本タスクにおいても，表現 r が信号の詳細な統計的特性を保持しており，これがテキストだけでは不足する情報を補完する強力な事前知識として機能すると考えられる．

表 4.2 条件付け手法の影響：PAMAP2 および REALWORLD における生成品質（FID, Precision, Recall）の比較．テキストと学習済み表現の組み合わせ（Text + Rep）は，テキストのみ（Text-Only）の条件付けを一貫して上回っており，表現を組み込むことで信号の忠実度が大幅に向上することを示している．

Dataset	Tuning Cond.	FID↓	Precision↑	Recall↑
PAMAP2	Text-Only	20.24	0.4843	0.5188
	Text + Rep	9.991	0.6300	0.6597
REALWORLD	Text-Only	12.33	0.2486	0.2480
	Text + Rep	8.261	0.6838	0.6925

実際に表現情報を加えたアブレーション実験の結果（表 4.2）は，表現を併用した場合（Text + Rep）が，テキストのみの場合（Text-Only）に比べて FID スコアが大幅に改善することを示している．これは，事前学習された表現 r が，生成に有用な情報を含んでいることの証左である．なお，推論時にはテキストのみから生成を行うため，表現 r は使用しない．

第5章 実験

本節では、提案手法の有効性を検証するための実験設定および結果について述べる．まず、5.1 節では使用したデータセットについて説明する．次に、5.2 節では人間行動認識（HAR）タスクを通じた表現品質の定量評価を行い、5.3 節ではテキスト記述を条件とする信号生成タスクによる定性評価を示す．最後に、5.4 節では、SenFlow の計算効率に関する評価結果を報告する．

なお、本研究で提案する SenFlow の有効性を厳密に検証するため、比較実験において重要なベースラインモデルを設計した．具体的には、SenFlow と全く同一の「表現エンコーダと生成ネットワークの分離・同時学習アーキテクチャ」を採用しつつ、生成メカニズムのみをフローマッチングから標準的な拡散モデルに置き換えたモデルを用意し、これを Diffusion Model-based Sensor Foundation Model (SenDiff) と名付けた．SenFlow と SenDiff の性能および計算コストを直接比較することで、提案アーキテクチャ自体の有効性と、フローマッチング導入による追加的な性能向上・効率化の効果を切り分けて定量的に評価する．

5.1 データセット

本実験では、手首に装着した IMU センサーから得られる 3 軸加速度データを使用する．Yuan et al. [45] の前処理に従い、連続的な信号を固定長のスライディングウィンドウに分割し、各ウィンドウを独立した入力サンプルとして扱う．実験に使用するすべてのデータは、ウィンドウサイズ 10 秒、サンプリング周波数 30 Hz に統一して再サンプリング処理を施した．

使用したデータセットの詳細を表 5.1 に示す．事前学習には、大規模生体データセットである Capture-24 [41] を使用した．本実験では、このデータセットに含まれるおよそ 140 万のスライディングウィンドウを、ラベルなしデータセットとみなして学習に利用した．下流タスクの評価には、行動認識で広く用いられる ADL [3]、Opportunity [31]、PAMAP2 [30]、REALWORLD [37]、WISDM [40] の計 5 つの公開データセットを使用した．

表 5.1 実験で使ったデータセット：事前学習用データセット (Capture-24) および 5 つの下流タスク用データセットの被験者数, サンプル数, クラス数を示す.

Phase	Dataset	Subjects	Samples	Classes
Pre-training	Capture-24 [41]	152	1.3M	4
Downstream Task	ADL [3]	7	0.6K	5
Downstream Task	Opportunity [31]	4	3.9K	4
Downstream Task	PAMAP2 [30]	8	2.9K	8
Downstream Task	REALWORLD [37]	14	12K	8
Downstream Task	WISDM [40]	46	28K	18

5.2 人間行動認識結果

事前学習により獲得した表現の品質を定量的に評価するため, HAR タスクを実施した. Accuracy (acc.) と F1-score (f1) の評価結果を表 5.2 に示す.

比較対象として, 以下の最先端および代表的なベースライン手法を採用した: (1) ウェアラブルデータにおけるマルチタスク学習で最先端の性能を達成している **SSL-Wearables** [45], (2) 自己蒸留に基づく対照学習手法 DINO [4] を 1 次元信号に適用した **1D-DINO**, (3) Transformer ベースのマスクモデリング等複数のプレテクストタスクを用いた手法である **SEnVt-u4** [26], (4) SEnVt-u4 の派生であり, より広範な追加タスクが含まれた, マルチタスク学習手法である **SEnVt-u7** [26], (4) 拡散モデルの生成過程を分類に応用する Li らの手法 [21] を 1 次元信号に適用した **1D-Diffusion Classifier**. さらに, アーキテクチャ分離の有効性を検証するための比較対象として, 前述の **SenDiff** の結果も併せて示す.

まず, 転移学習の結果について述べる. 我々の提案する SenFlow は, 5 つ全てのデータセットにおいて既存手法を上回る結果を達成した. 特に, 強力な対照学習ベースラインである 1D-DINO と比較して, REALWORLD データセットでは Accuracy で +7.02%, F1-score で +5.89% の向上を記録し, WISDM データセットにおいても Accuracy で +5.85%, F1-score で +6.06% の大幅な向上を達成した. ここで注目すべきは, 拡散モデルベースの SenDiff もまた, 既存手法を大きく上回る性能を示している点である. これは, 認識と生成を分離して同時学習させるという本研究のアーキテクチャ自体が, 表現学習において極めて有効であることを実証している. そして, SenFlow がその SenDiff をさらに上回っている事実は, 拡散モデルよりもフローマッチングを用いた方が, より良質な表現を獲得できることを示唆している.

次に, ファインチューニングの結果についても同様に, SenFlow は 5 つ全てのデー

表 5.2 **HAR 分類性能の比較**: 5つのデータセットにおける, SenFlow と最先端のベースライン (SSL-Wearables 等) の比較. SenFlow は, 転移学習とファインチューニングの両方の設定において, 一貫して最高の正解率 (acc.) と F1 スコア (f1) を達成している.

Method	ADL		Opportunity		PAMAP2		REALWORLD		WISDM	
	acc.	f1	acc.	f1	acc.	f1	acc.	f1	acc.	f1
Transfer learning										
SSL-Wearables [45]	-	.7540	-	.5470	-	.7250	-	.7710	-	.7230
1D-DINO	.8835	.8691	.7557	.7682	.8111	.7981	.8124	.8243	.7747	.7716
SEnVT-u4 [26]	.8394	.7936	.7103	.6826	.7157	.6912	.7470	.7512	.6667	.6618
SEnVT-u7 [26]	.8472	.7849	.7150	.6909	.7098	.6869	.7628	.7692	.6819	.6766
SenDiff (ours)	.9055	.8813	.7787	.7760	.8171	.8090	.8614	.8741	.8261	.8224
SenFlow (ours)	.9370	.9168	.7881	.7792	.8467	.8373	.8683	.8832	.8337	.8322
Fine-tuning										
Random Forest ¹	.8346	.6830	.6814	.4260	.6602	.5467	.6618	.5712	.4630	.4224
Transformer scratch ²	.8503	.8230	.6276	.6209	.7682	.7594	.8554	.8663	.8219	.8194
BERT [8]	.8583	.8553	.7272	.7245	.7561	.7527	.7807	.7819	.7923	.7924
SSL-Wearables [45]	-	.8290	-	.5950	-	.7890	-	.7920	-	.8100
1D-DINO	.9024	.8780	.7656	.7741	.8341	.8223	.8878	.8978	.8693	.8684
SEnVT-u4 [26]	.9087	.8780	.7489	.7411	.8488	.8454	.9015	.9124	.8693	.8679
SEnVT-u7 [26]	.8992	.8684	.7429	.7448	.8477	.8445	.9058	.9163	.8875	.8867
1D-Diffusion Classifier [21]	.8818	.8515	.7693	.7526	.8763	.8768	.8959	.8574	.8076	.8075
SenDiff (ours)	.9291	.9118	.7857	.7782	.8902	.8877	.9084	.9197	.8839	.8832
SenFlow (ours)	.9449	.9286	.7974	.7925	.8920	.8877	.9112	.9211	.8918	.8910

*1 Random Forest: 900-d input (concatenated x, y, z), depth 5, 10 trees.

*2 Transformer: depth 6, embedding dim 128, 4 heads, learning rate 0.001, 50 epochs.

タセットにおいて最高値を達成した. 特にベースラインの SSL-Wearables と比較した場合, F1-score において ADL で+9.96%, Opportunity で+19.75%, PAMAP2 で+9.87%, REALWORLD で+12.92%, WISDM で+8.10%という劇的な性能向上を実現した. これらの結果の一部として, REALWORLD と PAMAP2 における混合行列を図 5.1 に示す. 高い対角成分の値は, 各クラスを正確に識別できていることを示している.

さらに, 獲得された表現の質を視覚的に評価するため, 図 5.2 に t-SNE [38] を用いた低次元マッピングの結果を示す. ここでは, 事前学習データに含まれない未知のドメイン (PAMAP2 および REALWORLD) における表現の分布を可視化した. 左列の生データ (Raw) の分布では, 複数のアクティビティクラスが重なり合っており, 識別が困難であることがわかる. 一方, 右列の SenFlow による表現 (Representation) では, 事前学習時にクラスラベル情報を一切与えていないにもかかわらず, 明確なクラスター構造が形成されている. 特筆すべき点は, REALWORLD データセットにおいて「running」や「standing」といった動作が完全に独立した




図 5.1 HAR タスクにおける混合行列: 左図は PAMAP2 データセットにおける転移学習の結果を示し、右図は REALWORLD データセットにおけるファインチューニングの結果を示す。対角成分の強いパターンは、SenFlow が多様な行動クラスにわたって高い分類精度を示していることを実証している。

分布として分離されている点や、PAMAP2 において生データでは混在していたクラスが明瞭に分離されている点である。これは、提案手法が高い汎化能力と線形分離可能性を持つ表現を獲得していることを強く裏付けている。

5.3 Text-to-Signal 生成結果

SenFlow により獲得した表現が、単なる識別情報だけでなく、より豊かで意味的な構造を捉えているかを検証するため、テキスト記述を条件とする信号生成タスク (Text-to-Signal) を実施した。

テキスト条件の元データとして、被験者の身体的特徴 (年齢、性別、身長、体重) というメタ情報と、アクティビティラベルを含むデータセット (PAMAP2 及び REALWORLD) を利用した。本実験では、これらのメタ情報を単に機械的なテンプレートに埋め込むのではなく、人間が記述するような多様かつ自然なテキストプロンプトからの生成能力を検証するため、LLM を活用したプロンプトデータセットの構築を行った。具体的には、メタ情報と行動ラベルの組を入力とし、それを自然な英語の文章として記述するように Llama 3 (8B) に指示を与え、各サンプルに対応する自然言語記述を生成させた。これにより、図 5.3 に示すような多様な語彙と表現を含むテキスト条件を用意した。生成されたテキストプロンプトを条件ベクトルに変換するテキストエンコーダとしても、同様に事前学習済みの Llama 3 (8B) を利用した。なお、このテキストエンコーダ部分はモジュール化さ




図 5.2 表現の t-SNE 可視化:PAMAP2 および REALWORLD データセットにおける、生データ（左）と SenFlow による訓練済み表現（右）の比較. 学習された表現は、生データ空間では重複している行動クラスのクラスターを適切に分離しており、教師ラベルなしで高品質な特徴分離が実現されていることを示している.

れており、将来的には任意の LLM への拡張が可能である. 図 5.3 に、入力された自然言語プロンプトと、それに応じて生成された 3 軸加速度信号の波形例を示す. 生成された信号は、指定された行動（例:「walking」,「lying」）に特有の周期性や振幅パターンを視覚的に明確に再現している. 特に興味深い点は,「walking」と「walking downstairs」のように、動作としては類似しているが強度が異なる行動を指定した場合において、生成される信号の振幅や周期に一貫した差異が観察されたことである. また、被験者の属性情報に基づく個人差も反映されている様子が見て取れる. これは、我々のモデルが機械的なタグではなく、自然なテキストが内包する意味的なニュアンスを正しく解釈し、それを時系列データの詳細な統計的特性として表現する能力を持つことを示唆している.

さらに、生成データの分布特性を評価するため、図 5.4 に t-SNE による可視化結果を示す. ここでは PAMAP2 データセットの全てのインスタンスと、テキストプロンプトから生成された信号を同一空間上に描画した. 図中の色はアクティビティの種類、形は被験者を表している. 生成データ (Samples) の分布が、実データ (References) の分布と極めて良く重なり合っていることが確認できる. これは、提案手法が条件付き生成においてモード崩壊を起こすことなく、データの多様性を維持した高品質な生成を実現していることを示している.

これらの結果は、SenFlow がテキストのような抽象的な意味条件から、それに




図 5.3 Text-to-Signal 生成の例：テキストプロンプトを条件として生成された 3 軸加速度信号 (Samples) を、参照データ (References) と共に示す。モデルは、活動タイプ、強度、被験者の特徴などの意味的な記述を、現実的な時系列パターンに正確に変換しており、「歩行 (walking)」と「階段昇降 (climbing stairs)」のような異なる動作の特徴的なモーションを捉えている。

対応するリアルな時系列データを生成する能力を持つことを定性的に実証するものである。この Text-to-Signal 生成の成功は、シミュレーション用の合成データ生成や、特定の属性条件下でのデータ拡張など、実用的なアプリケーションへの展開可能性を大きく広げるものである。

5.4 計算効率の低減

最後に、SenFlow の計算効率について述べる。まず学習フェーズにおいて、SenFlow は総エネルギー消費の削減に大きく貢献した。フローマッチングは、複雑なノイズスケジュールを必要とする拡散モデルと比較して、学習が安定的かつ高速に収束するという特性を持つ。同一のハードウェア構成 (NVIDIA RTX 4090, バッチサイズ 1024) を用いた比較実験において、SenFlow の学習完了時間は約 3.2 時間であり、拡散モデルベースの SenDiff (約 6.5 時間) と比較して、学習時間を 50.4% 削減することに成功した。これは、大規模な基盤モデル開発において重要な課題である総消費エネルギーを半減させたことを意味し、Green AI の観点からも重要な貢献である。

次に推論フェーズにおいても、SenFlow は圧倒的な速度優位性を示した。表 5.3 に示す通り、SenFlow は高い生成品質 (FID: 5.014) を維持したまま、SenDiff (1000 ステップ) に対し最大 51.0 倍の高速化を実現した。また、高速化手法である DDIM (50-100 ステップ) を適用した拡散モデルと比較しても、2.53 倍～5.06 倍の速度向上を達成している。これは、生成品質を犠牲にすることなく、1 サンプル生成あた




図 5.4 生成された信号の t-SNE 可視化：PAMAP2 データセットにおける，実データ（References）とテキスト条件から生成された信号（Samples）の比較．生成データの分布は実データを密接に反映しており，モデルが活動タイプ（色）と個々の被験者の特徴（形）の両方について，明確なクラスター構造を捉えることに成功していることを示している．

りのレイテンシと消費電力の両方を劇的に削減できることを示している．この特性は，バッテリー制約のあるウェアラブルデバイスやエッジ AI 環境でのリアルタイム生成・処理を実現する上で極めて有利な性質である．

表 5.3 推論時の生成速度と品質:SenFlow は，高い生成品質（FID: 5.014）を維持しながら，拡散モデルベースの DiffFM（1000 ステップ）と比較して 51.0 倍の高速化を達成し，大幅な効率化を実証している．

Model	Steps	Time [s] / 1 sample ↓	FID ↓	IS ↑
SenDiff	1000	4.62×10^{-2}	5.047	2.751
SenDiff	100	4.58×10^{-3}	8.837	2.800
SenDiff	50	2.29×10^{-3}	10.08	2.819
SenFlow	-	9.05×10^{-4}	5.014	2.626

第6章 結論

本研究では、フローマッチングの強力な生成能力を表現学習へ直接応用する新しい基盤モデル SenFlow を提案した。SenFlow は、入力データから特徴を抽出する表現エンコーダと、その表現を条件としてデータ生成を行う速度ばネットワークを同時に訓練するアーキテクチャを採用した。これにより、データの本質的な構造を捉えたロバストな表現獲得と、従来の拡散モデルが抱えていた計算非効率性の解消を同時に実現した。

提案手法の有効性を検証するため、ウェアラブルセンサーデータを用いた複数の公開データセットで広範な評価を行った。人間行動認識タスクにおいては、SenFlow は最先端のベースラインである SSL-Wearables を含む既存の全ての SSL 学習手法を、全5つのデータセットにおいて凌駕する性能を示した。また、Text-to-Signal 生成タスクにおいては、獲得された表現とテキスト記述を組み合わせることで、被験者の属性や動作のニュアンスを反映した高品質な時系列信号を生成できることを確認した。これらの結果は、SenFlow が新しい原理に基づき、識別タスクと生成タスクの双方に応用可能な汎用的な表現を獲得できることを定量的に証明している。

計算効率の面では、SenFlow は拡散モデルベースの比較手法である SenDiff に対して、訓練時間を約 50%短縮し、総エネルギー消費量を半減させた。さらに推論速度においては、DiffFM と比較して最大 51.0 倍の高速化を実現しつつ、高い生成品質 (FID: 5.014) を維持しており、品質を犠牲にすることなく消費エネルギーを劇的に削減できることを実証した。これは、リソース制約のあるエッジデバイスやウェアラブルデバイスにおける実用的な基盤モデルの実現に向けた大きな一歩である。

今後の展望

本研究の今後の展望として、以下の2点が挙げられる。

第一に、多様なモダリティへの展開である。本研究では時系列センサデータを対象としたが、SenFlow で採用している表現と生成の共同学習というフレームワー

クは、データ形式に依存しない汎用的なものである。したがって、画像や動画、音声といったより高次元かつ複雑なデータ領域への適用、あるいはそれらを統合したマルチモーダル基盤モデルへの拡張が期待される。

第二に、計算効率化のメカニズムに関する詳細な解析である。本研究では、SenDiff と SenFlow の比較を通じて大幅な高速化を確認したが、提案手法の核である「DGS」や「共同学習」が、フローマッチングの速度場の幾何学的特性にどのような影響を与えているかについては、十分な検証がなされていない。特に、DGS による正則化が、ノイズからデータへの輸送経路をより直線的にする「速度場の整流化」に寄与している可能性が高いと考えている。経路が直線的になればなるほど、ODE ソルバは少ないステップ数で正確な解に到達できるため、これが本研究で観測された圧倒的な推論速度の向上（51 倍）の主要因であると推測される。今後は、生成過程におけるフローの曲率や輸送コストを定量的に解析し、提案手法が速度場の整流化に果たす役割を解明することで、さらなる訓練の効率化と推論の高速化を目指す研究を進めていきたい。

研究業績

査読付き学術論文・国際会議発表（全て査読あり）

1. **Kosuke Ukita**, Tsuyoshi Okita, “High-Performance Self-Supervised Representation Learning by Joint Training of Flow Matching and Representation Encoder,” *The 29th Annual Conference on Artificial Intelligence and Statistics (AISTATS 2026)*, Tangier, Morocco, May 2026. (Spotlight) (to appear)
2. Tsuyoshi Okita, **Kosuke Ukita**, Asahi Miyazaki, Daichi Kubota, Jukichi Ota, Naoki Kagiya, Asahi Nishikawa, Nagayasu Daichi, Syunya Tomitaka, Daisuke Nozaki, Yuki Odo, Raku Yamashita, Xiaolong Ye, Huayu Gao, Kazuki Okahashi, Koki Matsuishi, Masaharu Kagiya, Kodai Hirata, Haruki Kai, Lin Wang, Hristijan Gjoreski, Mathias Ciliberto, Paula Lago, Kazuya Murao, Daniel Roggen, “Foundation Models to Tackle Activity Recognition in Unknown Domain: Sussex-Huawei Locomotion Challenge 2025 Task 2,” *Companion of the 2025 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp Companion '25)*, pp. 983–991, Finland, 2025. (Oral)
3. Koki Matsuishi, **Kosuke Ukita**, Tsuyoshi Okita, “Multimodal Foundation Model for Cross-Modal Retrieval and Activity Recognition Tasks,” *International Journal of Activity and Behavior Computing (IJABC)*, Care XDX Center, Kyushu Institute of Technology, Vol. 2025, No. 3, pp. 1–25, 2025.
4. **Kosuke Ukita**, Tsuyoshi Okita, “Analysis of Human Activity Recognition by Diffusion Models,” *Companion of the 2024 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '24)*, pp. 458–463, Melbourne, Australia, October 2024. (Oral)
5. Tsuyoshi Okita, **Kosuke Ukita**, Koki Matsuishi, Masaharu Kagiya, Kodai Hirata, Asahi Miyazaki, “Towards LLMs for Sensor Data: Multi-Task

Self-Supervised Learning,” *Adjunct Proceedings of the 2023 ACM International Joint Conference on Pervasive and Ubiquitous Computing & the 2023 ACM International Symposium on Wearable Computing (UbiComp/ISWC ’23 Adjunct)*, pp. 499–504, Cancun, Mexico, October 2023. (Oral)

その他の論文・発表（全て査読なし）

6. **Kosuke Ukita**, Tsuyoshi Okita, “High-Performance Self-Supervised Learning by Joint Training of Flow Matching,” *arXiv preprint arXiv:2512.19729*, 2025. (Preprint)
7. **Kosuke Ukita**, Tsuyoshi Okita, “Energy-Efficient High-Performance Representation Learning for Sensor Data via Flow Matching,” *The 7th International Symposium on Neuromorphic AI Hardware*, Paper No. P-19, Kitakyushu, Japan, October 2025. (Poster)
8. **Kosuke Ukita**, Xiaolong Ye, Tsuyoshi Okita, “Image Classification Using a Diffusion Model as a PreTraining Model,” *arXiv preprint arXiv:2505.06890*, 2025. (Preprint)
9. 松石康希, **浮田嵩祐**, 大北剛, “AURA-MFM: 詳細な行動理解のための CLIP を用いたマルチモーダル基盤モデルの構築,” 情報処理学会研究報告 (IPSJ SIG Technical Report), Vol. 2025-UBI-85, No. 8, 大阪, 2025 年 2 月. (口頭)
10. **Kosuke Ukita**, Tsuyoshi Okita, “Improving Human Activity Recognition through Diffusion Models,” *The International Symposium on Applied Engineering and Sciences (SAES2024)*, No. p0052, Kitakyushu, Japan, November 2024. (Oral)
11. Asahi Miyazaki, **Kosuke Ukita**, Tsuyoshi Okita, “Ensemble Learning of Models for Human Activity Recognition,” *The International Symposium on Applied Engineering and Sciences (SAES2024)*, No. p0053, Kitakyushu, Japan, November 2024. (Oral)
12. **浮田嵩祐**, Ye Xiaolong, 大北剛, “表現条件付き潜在拡散モデルと表現学習,” 火の国情報シンポジウム 2024, 論文番号 A4-4, 鹿児島, 2024 年 3 月. (口頭)

投稿中（全て査読あり）

1. **Kosuke Ukita**, Tsuyoshi Okita, “Efficient Inference for Flow Matching via Unified Path CFG,” Submitted to *The 30th Pacific-Asia Conference on Knowledge Discovery and Data Mining (PAKDD 2026)*, Hong Kong, China, June, 2026.
2. 松石康希, **浮田嵩祐**, 大北剛, “拡散モデルを用いた人間行動モーションデータからの写実的な映像生成,” 情報処理学会論文誌 特集号「ユビキタスコンピューティングシステム (XIII)」, 2026 年 発行予定.

受賞

1. Kosuke Ukita, Tsuyoshi Okita, Spotlight (Top 3% of submissions), *The 29th Annual Conference on Artificial Intelligence and Statistics (AISTATS 2026)*, May 2026.
2. 浮田嵩祐, 情報処理学会九州支部 奨励賞, 2024 年 3 月.
3. 大塚功太郎, 浮田嵩祐, 関くるみ, 石井裕基, 第 8 回スポーツデータ解析コンペティション中等教育部門 最優秀賞, 2019 年 5 月.

参考文献

- [1] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Syndar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, Danielle C. Maddix, Michael W. Mahoney, Kari Torkkola, Andrew Gordon Wilson, Michael Bohlke-Schneider, and Yuyang Wang. Chronos: Learning the language of time series. *Transactions on Machine Learning Research*, 2024.
- [2] Florian Bordes, Randall Balestrieri, and Pascal Vincent. High fidelity visualization of what your self-supervised representation knows about. *arXiv preprint arXiv:2112.09164*, 2021.
- [3] Barbara Bruno, Fulvio Mastrogiovanni, Antonio Sgorbissa, Tullio Vernazza, and Renato Zaccaria. Analysis of human behavior recognition algorithms based on acceleration data. pages 1602–1607, 2013.
- [4] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 9650–9660, 2021.
- [5] Ricky TQ Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. *Advances in neural information processing systems*, 31, 2018.
- [6] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pages 1597–1607. PMLR, 2020.
- [7] Xinlei Chen, Zhuang Liu, Saining Xie, and Kaiming He. Deconstructing denoising diffusion models for self-supervised learning. *arXiv preprint arXiv:2401.14404*, 2024.

- [8] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.
- [9] Mischa Dombrowski, Hadrien Reynaud, Johanna P Müller, Matthew Baugh, and Bernhard Kainz. Trade-offs in fine-tuned diffusion models between accuracy and interpretability. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 21037–21045, 2024.
- [10] Jiaxiang Dong, Haixu Wu, Haoran Zhang, Li Zhang, Jianmin Wang, and Mingsheng Long. Simmtm: A simple pre-training framework for masked time-series modeling. *Advances in Neural Information Processing Systems*, 36:29996–30025, 2023.
- [11] Alexey Dosovitskiy. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [12] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. *Advances in neural information processing systems*, 27:1–9, 2014.
- [13] Mononito Goswami, Konrad Szafer, Arjun Choudhry, Yifu Cai, Shuo Li, and Artur Dubrawski. Moment: A family of open time-series foundation models. In *International Conference on Machine Learning*, 2024.
- [14] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 16000–16009, 2022.
- [15] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. *arXiv preprint arXiv:1911.05722*, 2019.
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.

- [17] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- [18] Lei Huang, Tingyang Xu, Yang Yu, Peilin Zhao, Xingjian Chen, Jing Han, Zhi Xie, Hailong Li, Wenge Zhong, Ka-Chun Wong, et al. A dual diffusion model enables 3d molecule generation and lead optimization based on target pockets. *Nature Communications*, 15(1):2657, 2024.
- [19] Drew A Hudson, Daniel Zoran, Mateusz Malinowski, Andrew K Lampinen, Andrew Jaegle, James L McClelland, Loic Matthey, Felix Hill, and Alexander Lerchner. Soda: Bottleneck diffusion models for representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 23115–23127, 2024.
- [20] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, pages 1–14, 2013.
- [21] Alexander C Li, Mihir Prabhudesai, Shivam Duggal, Ellis Brown, and Deepak Pathak. Your diffusion model is secretly a zero-shot classifier. *arXiv preprint arXiv:2303.16203*, 2023.
- [22] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [23] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.
- [24] Caspar Meijer and Lydia Y Chen. The rise of diffusion models in time-series forecasting. *arXiv preprint arXiv:2401.03006*, 2024.
- [25] Shen Nie, Fengqi Zhu, Zebin You, Xiaolu Zhang, Jingyang Ou, Jun Hu, Jun Zhou, Yankai Lin, Ji-Rong Wen, and Chongxuan Li. Large language diffusion models. *arXiv preprint arXiv:2502.09992*, 2025.
- [26] Tsuyoshi Okita, Kosuke Ukita, Koki Matsuishi, Masaharu Kagiya, Kodai Hirata, and Asahi Miyazaki. Towards llms for sensor data: Multi-task self-supervised learning. In *Adjunct Proceedings of the 2023 ACM International*

Joint Conference on Pervasive and Ubiquitous Computing & the 2023 ACM International Symposium on Wearable Computing, pages 499–504, 2023.

- [27] OpenAI. Gpt-4 technical report. *CoRR abs/2303.08774*, pages 1–100, 2023.
- [28] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [29] William Peebles and Saining Xie. Scalable diffusion models with transformers. pages 4195–4205, 2023.
- [30] Attila Reiss and Didier Stricker. Introducing a new benchmarked dataset for activity monitoring. *2012 16th international symposium on wearable computers*, pages 108–109, 2012.
- [31] Daniel Roggen, Alberto Calatroni, Mirco Rossi, Thomas Holleczeck, Kilian Förster, Gerhard Tröster, Paul Lukowicz, David Bannach, Gerald Pirkel, Alois Ferscha, et al. Collecting complex activity datasets in highly rich networked sensor environments. *2010 Seventh international conference on networked sensing systems (INSS)*, pages 233–240, 2010.
- [32] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 10684–10695, 2022.
- [33] Yorai Shaoul, Itamar Mishani, Shivam Vats, Jiaoyang Li, and Maxim Likhachev. Multi-robot motion planning with diffusion models. *arXiv preprint arXiv:2410.03072*, 2024.
- [34] Kai Shen, Zeqian Ju, Xu Tan, Yanqing Liu, Yichong Leng, Lei He, Tao Qin, Sheng Zhao, and Jiang Bian. Naturalspeech 2: Latent diffusion models are natural and zero-shot speech and singing synthesizers. *arXiv preprint arXiv:2304.09116*, 2023.
- [35] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, Francisco Massa, Daniel Haziza, Luca Wehrstedt,

- Jianyuan Wang, Timothée Darcet, Théo Moutakanni, Leonel Sentana, Claire Roberts, Andrea Vedaldi, Jamie Tolan, John Brandt, Camille Couprie, Julien Mairal, Hervé Jégou, Patrick Labatut, and Piotr Bojanowski. DINOv3, 2025.
- [36] Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020.
- [37] Timo Sztyler and Heiner Stuckenschmidt. On-body localization of wearable devices: An investigation of position-aware activity recognition. pages 1–9, 2016.
- [38] Laurens Van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 9(11), 2008.
- [39] Guanghan Wang, Yair Schiff, Subham Sekhar Sahoo, and Volodymyr Kuleshov. Remasking discrete diffusion models with inference-time scaling. *arXiv preprint arXiv:2503.00307*, 2025.
- [40] Gary M Weiss, Kenichi Yoneda, and Thaier Hayajneh. Smartphone and smartwatch-based biometrics using activities of daily living. *IEEE Access*, 7:133190–133202, 2019.
- [41] Matthew Willetts, Sven Hollowell, Louis Aslett, Chris Holmes, and Aiden Doherty. Statistical machine learning of sleep and physical activity phenotypes from sensor data in 96,220 uk biobank participants. *Scientific reports*, 8(1):1–10, 2018.
- [42] Weilai Xiang, Hongyu Yang, Di Huang, and Yunhong Wang. Denoising diffusion autoencoders are unified self-supervised learners. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 15802–15812, 2023.
- [43] Xingyi Yang and Xinchao Wang. Diffusion model as representation learner. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 18938–18949, 2023.
- [44] Sihyun Yu, Sangkyung Kwak, Huiwon Jang, Jongheon Jeong, Jonathan Huang, Jinwoo Shin, and Saining Xie. Representation alignment for genera-

- tion: Training diffusion transformers is easier than you think. In *International Conference on Learning Representations*, 2025.
- [45] Hang Yuan, Shing Chan, Andrew P Creagh, Catherine Tong, Aidan Acquah, David A Clifton, and Aiden Doherty. Self-supervised learning for human activity recognition using 700,000 person-days of wearable data. *npj Digital Medicine*, 7(1):1–18, 2024.
 - [46] Haiyu Zhang, Xinyuan Chen, Yaohui Wang, Xihui Liu, Yunhong Wang, and Yu Qiao. 4diffusion: Multi-view video diffusion model for 4d generation. *Advances in Neural Information Processing Systems*, 37:15272–15295, 2024.
 - [47] Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. ibot: Image bert pre-training with online tokenizer. *International Conference on Learning Representations (ICLR)*, 2022.