



表現条件付き潜在拡散モデルと表現学習

九州工業大学大学院 情報工学研究院知能情報工学研究系
大北研究室

浮田嵩祐 YE Xiaolong 大北剛



構成

- **前提知識**

- 拡散モデル
- 自己教師あり学習

- **提案手法**

- 拡散モデルによる自己教師あり学習
- 表現条件付き潜在拡散モデル

- **関連研究**



- 対比学習手法: ビジョントランスフォーマーDINO

- **実験結果**

- **考察**


- **結論**

拡散モデル



- モデルはノイズ除去を学習する
- 訓練後, 完全なノイズから鮮明な画像を生成する

潜在拡散モデル



- 画像を圧縮した潜在空間上で拡散モデルを構築

潜在拡散モデル

潜在拡散モデル




図:潜在拡散モデル

(出典: Robin Rombach ら, 'High-resolution image synthesis with latent diffusion models', 2021.).

- "Stable Diffusion"として公開された
- ノイズ除去ネットワークはU-Netを採用

拡散トランスフォーマー：Diffusion Transformers(DiT)

トランスフォーマー(Transformers)：

- 2017年に発表された“Attention Is All You Need”という自然言語処理の論文の中で提案された深層学習モデル.
- 従来のモデルより学習コストが低く, 精度が高いということで効果が示された.

拡散トランスフォーマー(Diffusion Transformers (DiT))：

- 潜在拡散モデルのノイズ除去ネットワークをトランスフォーマーで構築.
- 2022年にDiTとという名前で提案され, 従来のすべての拡散モデルを上回り効果が示された. (FID 2.27を達成).




図: 拡散トランスフォーマーDiT(クラス条件付き潜在拡散モデル)

自己教師あり学習


プレテックストタスク：ラベルなしデータで事前学習モデルを学習する。

ダウンストリームタスク：学習した事前学習モデルを用いて少量のラベルありデータで訓練する。

プレテックストタスク



ダウンストリームタスク




プレテックストタスクの例

Colorization



[Richard Zhangら, 2016.]

Jigsaw Puzzle



[Mehdi Norooziら, 2017.]

Rotation




[Spyros Gidarisら, 2018.]


提案手法

アイデア： 拡散モデルを使用して自己教師あり学習を行う

Step 1



Step 2



- ラベルなしデータで拡散モデルを学習する
- 少量のラベルありデータを使用し、ラベルを条件付けながら拡散モデルを学習する
 - 意図した画像を生成するための要素
 - **テキストから画像**を生成するモデルは「**テキスト条件付き**拡散モデル」と呼ぶ
- クラスラベル条件付き拡散モデルから分類子を取り出す手法「**拡散分類器**」を用いて分類結果を得る

拡散分類器

目的: 拡散モデルを使って画像分類をする

- 拡散モデルはノイズ除去による画像生成が可能
- 拡散モデルの訓練目的は受け取った画像に含まれる元ノイズを予測すること




図: クラスラベル'1'を条件付けながら生成している過程

拡散モデルの訓練目的





図: 拡散モデルの訓練の目的

拡散分類器

- すべてのラベルを条件付けて元ノイズを予測する
- 予測したノイズから元画像 z_0 を予測した z_0' を計算する



提案モデル：表現条件付き潜在拡散モデル




図: DiT内部にビジョントランスフォーマーを組み込み、画像表現をノイズ除去ネットワークに結合したモデル
 図: 拡散トランスフォーマーを組み込み、ViT(画像表現付き潜在拡散モデル)に結合したモデル
 (表現条件付き潜在拡散モデル)

それぞれのモデル

提案するモデル




図:クラス条件付き潜在拡散モデル(DIT)




図:無条件潜在拡散モデル




図:表現条件付き潜在拡散モデル

事前学習：ラベルが不要な「無条件潜在拡散モデル」と「表現条件付き潜在拡散モデル」で事前学習を行う

チューニング：「クラス条件付き潜在拡散モデル」でクラスラベルを条件付けて訓練する

生成モデルとしての評価

- 脳CTスライス画像データを使用して訓練した。




表:条件別潜在拡散モデルの評価結果

Conditions	FID↓	sFID↓	IS↑	Precision↑	Recall↑
クラス条件付き潜在拡散モデル (DiT)	25.69	21.57	<u>3.257</u>	0.39	0.36
無条件潜在拡散モデル	24.42	20.98	3.117	0.40	0.39
表現条件付き潜在拡散モデル	<u>10.00</u>	<u>12.20</u>	3.204	<u>0.94</u>	<u>0.99</u>

提案するモデル






図:事前学習用データの分布(黒)と生成データの分布(青)との比較。(左)クラス条件付き,(中央)無条件,(右)表現条件付き

生成モデルとしての評価：生成画像

クラス条件付き潜在拡散モデル(DiT)


条件

クラスラベル

0, 1



生成サンプル




無条件潜在拡散モデル

条件

ランダム



生成サンプル




表現条件付き潜在拡散モデル

条件

表現



生成サンプル




- 条件が異なるため，モデルごとの生成画像を単純に比較することが困難

生成モデルとしての評価：生成画像

- 完全なノイズ($t=1000$)からではなく，特定のタイムステップからノイズ除去により生成する

タイムステップに応じたノイズを付与


元画像



クラス条件付き潜在拡散モデル(DiT)

無条件潜在拡散モデル

表現条件付き潜在拡散モデル




生成モデルとしての評価：生成画像

元画像




生成画像


クラス条件付き潜在拡散モデル(DiT)



無条件潜在拡散モデル



表現条件付き潜在拡散モデル



- **血腫**（頭蓋内灰色の部分）の形が異なる
- **側脳室**（頭蓋内黒色の部分）の形が異なる
- 後頭葉周辺の**しわ**が異なる

「**表現条件付き**潜在拡散モデル」が
元画像を最も再現できている

拡散モデルを用いた自己教師あり学習の評価




図: 拡散モデルを用いた自己教師あり学習手法

- 自己教師あり学習の一つである対比学習手法：ビジョントランスフォーマー**DINO**
強力な対比学習手法として効果が示された。
- **DINO**の改良版モデル**DINOv2**と本研究手法との比較により評価

関連研究

DINO(self-distillation with no labels) :

- 自己教師あり学習の1つである**対比学習手法**として提案された.
- 画像に異なる2つのデータ拡張を施し出力された特徴のクロスエントロピー損失を下げるように訓練される.




図:DINOアルゴリズム(出典: Caronら, <https://github.com/facebookresearch/dino>, 2021).

関連研究

DINO(self-distillation with no labels) :

- 自己教師あり学習の1つである**対比学習手法**として提案された.
- 画像に異なる2つのデータ拡張を施し出力された特徴のクロスエントロピー損失を下げるように訓練される.
- 事前学習されたモデルを用いて特徴空間を可視化すると物体認識のようなことができていた.




図:事前学習されたVision Transformerからのself-attention (出典: Caronら, <https://github.com/facebookresearch/dino>, 2021).

- DINOから改良されたDINOv2と本研究結果との比較で評価する.

実験結果

表:ダウンストリーム用テストデータでの分類結果

Pre-training	Classification	Accuracy	F-score	Recall	Precision
None	ResNet50	0.7150	0.4950	<u>0.8928</u>	0.3424
None	ViT B	0.8659	0.5200	0.4642	0.5909
DINOv2	Linear	0.8882	0.6875	0.7857	0.6111
無条件潜在拡散モデル	zero-shot	0.8882	0.7058	0.8571	0.6000
表現条件付き潜在拡散モデル	zero-shot	<u>0.9497</u>	<u>0.8235</u>	0.7500	<u>0.9130</u>





図:タイムステップごとの分類結果(事前学習：表現条件付き潜在拡散モデル)

拡散モデルの訓練目的

拡散モデルの訓練目的: 受け取った画像に含まれるソースノイズを予測すること

→ ノイズを含む画像を元ノイズと元画像に分割すること



無条件潜在拡散モデルと表現条件付き潜在拡散モデルの違い

拡散モデルの逆拡散過程（生成過程）

無条件潜在拡散モデル





図:逆拡散過程(上)と, そのノイズからの元画像予測結果(下)

表現条件付き潜在拡散モデル






図:逆拡散過程(上)と, そのノイズからの元画像予測結果(下)

無条件潜在拡散モデルと表現条件付き潜在拡散モデルの違い



- ・ **表現条件付き** 潜在拡散モデルの方が小さい値まで下がっている。

無条件潜在拡散モデルと表現条件付き潜在拡散モデルの違い

- 表現を条件付けることで訓練が易しくなっている

元画像の情報を持つ**表現**が**訓練の助け**になっていると思われる.

- 無条件モデルでは到達できないレベルまで学習が可能

損失の最小値で比較すると, 10^2 スケールの差が出ている.

- ・ 無条件潜在拡散モデル : 3.13×10^{-2}
- ・ 表現条件付き潜在拡散モデル : 3.39×10^{-4}

- 以上の違いが画像分類結果の差を生んだと考える

- 表現条件付き潜在拡散モデルの提案

生成した画像はベースラインのDiTと比較するとFIDが15.69向上した.

- 拡散モデルを用いた自己教師あり学習手法の提案

事前学習に表現条件付き潜在拡散モデルを使用した場合は, DINOv2と比較して
Accuracyが6.15%, F値が13.6%上回った.

- データセットを変更したり，大規模にしたりして実験をおこなう

本実験では，10,313枚の脳CTスライス画像データセットを使用した．

- ・ CQ500（193,317枚の脳CTスライス画像データセット）
- ・ ImageNet-1k（1,281,167枚の自然画像データセット）

- 個人を表す条件付け訓練を行い，個人差を考慮した脳画像生成をおこなう

参考文献

- Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Bjorn Ommer. ‘High-resolution image synthesis with latent diffusion models.’ In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 10684–10695, 2022.
- William Peebles and Saining Xie. ‘Scalable diffusion models with transformers.’ arXiv preprint arXiv:2212.09748, 2022.
- Mathilde Caron, Hugo Touvron, Ishan Misra, Herve Jegou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. ‘Emerging properties in self-supervised vision transformers.’ In Proceedings of the IEEE/CVF international conference on computer vision, pp. 9650–9660, 2021.
- Maxime Oquab, Timothee Darcet, Theo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. ‘Dinov2: Learning robust visual features without supervision.’ arXiv preprint arXiv:2304.07193, 2023.
- Mehdi Noroozi and Paolo Favaro. Unsupervised Learning of Visual Representations by Solving Jigsaw Puzzles.’ arXiv preprint arXiv:1603.09246, 2017.
- Richard Zhang, Phillip Isola and Alexei A. Efros. ‘Colorful Image Colorization.’ arXiv preprint arXiv:1603.08511, 2016.
- Spyros Gidaris, Praveer Singh and Nikos Komodakis. ‘Unsupervised Representation Learning by Predicting Image Rotations.’ arXiv preprint arXiv:1803.07728, 2018.

補足資料

補足：データセットについて

表: プレテキストタスクとダウンストリームタスクに使用する脳CT画像のデータ数

タスク	病院番号	データ数
プレテキストタスク	2 から 12	10,313
ダウンストリームタスク	1	1,781

表: ダウンストリームタスクに使用する脳CT画像の用途別データ数

データ用途	データ数
訓練データ	1,424
検証データ	178
テストデータ	179
計	1,781

補足：生成モデルの評価指標

openAIが公開しているImageNetで訓練されたInception-v3というモデルを使用して計算している。
事前学習用のデータ10,313枚と、生成したデータ10,000枚を比較する。

- **FID(Frechet Inception Distance):** 実際の画像と生成された画像の間の特徴距離を測定するための指標。
 - **sFID(spatial Frechet Inception Distance):** Nashらが提案したFIDの派生指標である。sFIDはInception-v3から得られる2つの特徴を使用して計算される。1つは、FIDの計算にも使用される標準の”pool3:0”からの特徴であり、もう1つは、”mixed 6/conv:0”から7チャンネル分の特徴である。この2つを使用してFID導出と同様の計算で導出される。後者を含める理由は、モデル間の空間分布の類似性の感覚を提供する為であり、**空間的な違いを考慮**している。
 - **IS(Inception Score):** Inception-v3の分類結果が使用される。生成された**画像の質と多様性**を評価する指標。任意の画像の分類精度で画像の質を測り、すべての画像の分類結果数の散らばりから多様性を測る。この値は高いほど、生成される画像の質と多様性が保証される。
- ただ、Inception-v3は**ImageNetで訓練**されているため、本実験で使用した脳画像を入力すると分類結果が正しいものでないため**正しい結果が得られない**と考える。

補足：DiTについて

Model	Layers N	Hidden size d	Heads	Gflops ($I=32, p=4$)
DiT-S	12	384	6	1.4
DiT-B	12	768	12	5.6
DiT-L	24	1024	16	19.7
DiT-XL	28	1152	16	29.1

Table 1. **Details of DiT models.** We follow ViT [10] model configurations for the Small (S), Base (B) and Large (L) variants; we also introduce an XLarge (XL) config as our largest model.





Figure 9. **Larger DiT models use large compute more efficiently.** We plot FID as a function of total training compute.

補足：拡散モデルのパラメータスケジューリング



補足：拡散モデルの式

$$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

$$z_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(z_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta \right) + \sigma_t \cdot \epsilon$$

$$z'_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(z_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta \right)$$

補足：表現条件付き潜在拡散モデルを構築した理由





表: 表現条件付き潜在拡散モデル内部の表現を使用した分類結果との比較

Pre-training	Classification	Accuracy	F-score	Recall	Precision
None	ResNet50	0.7150	0.4950	<u>0.8928</u>	0.3424
None	ViT B	0.8659	0.5200	0.4642	0.5909
DINOv2	Linear	<u>0.8882</u>	<u>0.6875</u>	0.7857	<u>0.6111</u>
表現条件付きモデル内部の表現	Linear	0.8379	0.3555	0.2857	0.4705

補足：損失の推移



補足：タイムステップごとの分類結果




図: タイムステップごとの分類結果(事前学習：無条件)




図: タイムステップごとの分類結果(事前学習：表現条件付き)